

**ESTUDO DE MÉTODOS PARA CLASSIFICAÇÃO E  
LOCALIZAÇÃO PRECISA DE PADRÕES USANDO UM  
SISTEMA DE LUZ ESTRUTURADA**

**Christiane Nogueira de Carvalho Kokubum**

**Presidente Prudente**

**2004**

**CHRISTIANE NOGUEIRA DE CARVALHO KOKUBUM**

**ESTUDO DE MÉTODOS PARA CLASSIFICAÇÃO E  
LOCALIZAÇÃO PRECISA DE PADRÕES USANDO  
UM SISTEMA DE LUZ ESTRUTURADA**

Dissertação apresentada ao Programa de Pós-Graduação em Ciências Cartográficas da Faculdade de Ciências e Tecnologia da UNESP, como parte dos requisitos exigidos para a obtenção do título de Mestre em Ciências Cartográficas.

**Orientador:**

**Prof. Dr. Antonio M. G. Tommaselli**

Presidente Prudente

2004

## RESUMO

Algumas das tarefas mais significativas em Visão Computacional e em Fotogrametria Digital à curta distância estão associadas à segmentação, ao reconhecimento de objetos na imagem e à posterior reconstrução. Esta dissertação apresenta uma metodologia para a identificação e para a medição automáticas de alvos projetados em imagens tomadas à curta-distância, usando o sistema ativo denominado luz estruturada. Para a classificação de tais padrões, dois métodos de correspondência são comparados: correspondência por padrão (*template matching*) e por assinatura. O método de correspondência por padrão consiste na classificação por correlação, que mede a similaridade entre as janelas de referência e de busca utilizando uma função de correlação adequada. Os problemas existentes neste método estão relacionados com os ruídos na imagem, variações de brilho, distorções geométricas, o grande número de padrões a serem comparados e a escolha do tamanho do padrão. O método de assinatura consiste na comparação da representação funcional unidimensional da fronteira do padrão. Este método de assinatura não varia em relação à translação, mas depende da rotação e da mudança de escala. Para a localização precisa, dois métodos foram comparados: correspondência por mínimos quadrados e detector de cantos. O método de correspondência por mínimos quadrados refina a correspondência obtida por correlação, estimando os parâmetros de transformação radiométricos e geométricos entre as janelas de referência e de pesquisa, de acordo com o critério de erro dos mínimos quadrados. Já o detector de cantos determina as coordenadas subpixel usando uma combinação dos operadores de Moravec e de Förstner. Experimentos realizados com dados simulados e reais foram conduzidos com o objetivo de verificar a eficácia da metodologia com respeito à detecção e a localização precisa. Os resultados mostram que a metodologia de classificação funciona adequadamente, identificando 98% de alvos em superfícies planas e 93% em superfícies oblíquas. Os métodos de correspondência por mínimos quadrados e detector de cantos mostraram-se equivalentes para a localização precisa.

Palavras-chave: Correlação, correspondência por mínimos quadrados, luz estruturada, assinatura, reconhecimento de padrões, detecção de cantos.

## **ABSTRACT**

Some of the main tasks in computer vision and close range Photogrammetry are related to the processes of segmentation, object recognition in the image and later reconstruction. The aim of this work is to study an automatic recognition system to identify and to measure targets projected with a structured light system. For target recognition two methods are compared: template matching and the signature method. The template matching method consists in the detection of area similarity by correlation. The idea of correlation is to compare the gray level distribution of a small sub image with its homologous in the search image. In this paper, the function used is the modified cross covariance which presented the best results. The problems in this method are related to illumination differences between the two images, geometric distortions, noise, the great number of templates to be compared and determination of template size. The signature method is based in the analysis of the one-dimensional representation of target border. The signature depends on the rotation and the scale changes of the target. Two methods were compared for precise localization: LSM (least square matching) and corner detection. The idea of least squares matching is to minimize the gray level differences between the image patch and the matching window; the geometric and radiometric parameters from the template to the matching window are determined in the adjustment process. The corner detection consists in the determination of the subpixel coordinates of corners using the Förstner and Moravec operators. Experiments were performed, in order to verify the performance of the methodology for detection and precise localization. The results showed that the classification works appropriately, identifying 98% of targets in plane surfaces and 93% in oblique surfaces. Besides, the results of precise localization were equivalent in both methods: LSM and corner detection.

**Keywords:** Template matching, structured light, signature, recognition of targets, corner detection.

## LISTA DE FIGURAS

FIGURA 1 - Princípio de formação de uma imagem digital.....	25
FIGURA 2 – Definição do sistema de coordenadas de uma imagem digital.....	26
FIGURA 3 – Regiões definidas no processo de limiarização local.....	37
FIGURA 4 – Representação das magnitudes dos gradientes e do ângulo de direções das bordas.....	39
FIGURA 5 – Máscaras usadas no operador de Sobel(a) Gradiente em x; (b) Gradiente em y.....	40
FIGURA 6 - Janelas 3x3 mostrando os vetores de 0°, 45°, 90° e 135°, respectivamente .....	42
FIGURA 7 - Ferramenta de produção automotiva .....	47
FIGURA 8 - Padrão desenvolvido por Dunn e Keizer (1989).....	53
FIGURA 9 - Detalhe do padrão binário projetado. ....	54
FIGURA 10 - O padrão de iluminação composto de quatro primitivas.....	54
FIGURA 11 – Pesquisa bidimensional de imagens correlatas. ....	59
FIGURA 12 - Representação do <i>pixel</i> reamostrado.....	69
FIGURA 13 – Padrões que reduzem a quantidade de parâmetros a serem determinados pelo modelo matemático mencionado nesta seção. (a) escala em y; (b) rotação; (c) duas escalas; (d) todos na direção y; (e) todos na direção y e escala em x; (f) todos.....	70
FIGURA 14 – Fronteiras e suas respectivas assinaturas.....	71
FIGURA 15 – Assinatura: (a) Princípio da construção (b) Assinaturas para um círculo e um triângulo. ....	71
FIGURA 16 – Alvo codificado.....	78
FIGURA 17 – Seqüência das operações e processamentos realizados.....	80
FIGURA 18 - Padrões primitivos. ....	82
FIGURA 19 – Vizinhança dos padrões. ....	83
FIGURA 20 - Sistema sensor e projetor.....	84
FIGURA 21 – Configuração da janela do limiar local.....	86
FIGURA 22 – Fluxograma do algoritmo de segmentação de padrões.....	89
FIGURA 23 - Padrão com diferentes rotações e idênticas assinaturas. ....	93
FIGURA 24 – Pontos iniciais dos padrões utilizados. ....	93

FIGURA 25 – Direções obtidas dos pontos.....	94
FIGURA 26 – Exemplo de uma imagem de padrões. ....	101
FIGURA 27 - Dimensão dos padrões projetados em <i>pixel</i> .....	101
FIGURA 28 – Resultados da limiarização. (a) Imagem original; (b) Método de expansão do histograma; (c) Método de transformação local. ....	102
FIGURA 29 - (a) Imagem original (tomada de um dorso humano) com o sistema de luz estruturada; (b) Parte da imagem original; (c) (d) Limiarização com o método de Otsu local; (e) (f) Limiarização com Pun local .....	104
FIGURA 30 – Resultados de imagens segmentadas. (a) Todos os alvos foram segmentados. (b) Alguns alvos não foram segmentados.....	105
FIGURA 31 – Resultados da correspondência por correlação usando padrões binários (imagens invertidas). (a) Imagem dos alvos projetados em um cilindro; (b) Imagem realçada de uma imagem sem variação de rotação; (c) Classificação dos alvos para a imagem com padrões projetados distorcidos; (d) Imagem realçada de uma imagem com variação na rotação; (e) Classificação dos alvos para a imagem com padrões projetados distorcidos.....	110
FIGURA 32 - Classificação dos alvos de um cilindro após a segmentação.....	111
FIGURA 33 - Classificação dos alvos após a segmentação de um dorso humano ..	111
FIGURA 34 – Resultados da correspondência por correlação usando padrões suavizados pela média (imagens invertidas) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos. ....	113
FIGURA 35 – Resultados da correspondência por correlação usando padrões reamostrados (Padrões 23 <i>pixels</i> x 23 <i>pixels</i> ) (imagens invertidas) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.....	115
FIGURA 36 – Reamostragem dos padrões primitivos sem moldura.....	116
FIGURA 37 – Resultados da correspondência por correlação usando padrões reamostrados sem bordas (Padrões 90 <i>pixels</i> x 90 <i>pixels</i> ) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem	

sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.....	117
FIGURA 38 – Resultados da correspondência por correlação usando padrões reamostrados usando molduras (Padrões 90 <i>pixels</i> x 90 <i>pixels</i> ) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.....	118
FIGURA 39 – Extração de fronteiras usando o método de perseguição de fronteiras.(a) Extração de fronteiras dos alvos projetados em um cilindro;(b) Detalhe da imagem com as fronteiras dos alvos extraídos.....	120
FIGURA 40 - Assinatura dos padrões armazenados. ....	121
FIGURA 41 – Assinaturas dos padrões e dos alvos segmentados.....	123
FIGURA 42 – Resultado da classificação usando o método de assinatura. ....	124
FIGURA 43 - Localização precisa dos alvos usando padrões pré-definidos.....	126
FIGURA 44 – Localização precisa usando o método de reamostragem dos padrões. ....	127
FIGURA 45 – Localização precisa por detecção de cantos usando padrões reamostrados.....	128
FIGURA 46 – Uma das quatro imagens usadas para calibração da câmara.....	129

## LISTA DE TABELAS

TABELA 1 – Resolução espacial. ....	24
TABELA 2 – Resolução radiométrica. ....	25
TABELA 3 – Exemplos de aplicações de reconhecimento de padrões.....	58
TABELA 4 - Parâmetros de orientação interior calibrados.....	85
TABELA 5 - Padrões pré-definidos e as suas instâncias armazenadas. ....	90
TABELA 6 – Exemplo de saída do reconhecimento de padrões. ....	129
TABELA 7 - Métodos usados e respectivos erros médios quadrático usando apenas os alvos do tipo A. ....	131
TABELA 8 – Resultados da reconstrução usando o método de detector de cantos para todos os cinco padrões.....	132



# CONTEÚDO

## CAPÍTULO I

1. INTRODUÇÃO .....	18
1.1. <i>Considerações iniciais</i> .....	18
1.2. <i>Objetivos</i> .....	21
1.2.1. <i>Objetivo geral</i> .....	21
1.2.1. <i>Objetivos específicos</i> .....	21
1.3. <i>Estrutura do trabalho</i> .....	23

## CAPÍTULO II

2. IMAGENS DIGITAIS: AQUISIÇÃO E PROCESSAMENTO .....	24
2.1. <i>Imagem Digital</i> .....	24
2.2. <i>Câmaras digitais</i> .....	25
2.3. <i>Sistemas de coordenadas</i> .....	26
2.4. <i>Efeitos sistemáticos</i> .....	27
2.5. <i>Melhoramento de contraste linear</i> .....	29
2.5.1. <i>Método de expansão do histograma</i> .....	29
2.5.2. <i>Transformação local</i> .....	30
2.6. <i>Segmentação</i> .....	32
2.7. <i>Limiarização</i> .....	33
2.7.1. <i>Método de Otsu</i> .....	34
2.7.2. <i>Método de Pun</i> .....	36
2.7.3. <i>Limiarização local</i> .....	37
2.8. <i>Deteção de bordas</i> .....	38
2.8.1. <i>Operadores de gradiente</i> .....	38
2.8.1.1. <i>Operadores de Sobel</i> .....	40
2.9. <i>Detector de cantos</i> .....	41
2.9.1. <i>Operadores de interesse</i> .....	41
2.9.1.1. <i>Operador de Moravec</i> .....	41

2.9.1.2. Operador de Förstner .....	43
2.9.2. Técnica híbrida usada para detecção de cantos .....	44

### **CAPÍTULO III**

3. FOTOGRAMETRIA À CURTA DISTÂNCIA .....	46
3.1. Aplicações da Fotogrametria à curta distância .....	46
3.2. Luz estruturada.....	49
3.2.1. Técnicas utilizando o sistema de luz estruturada.....	50

### **CAPÍTULO IV**

4. RECONHECIMENTO DE PADRÕES .....	57
4.1. Correspondência por padrão (Template matching) .....	59
4.1.1. Funções básicas de correlação .....	60
4.1.1.1. Função covariância cruzada.....	61
4.1.1.2. Função covariância cruzada modificada ou coeficiente de correlação.....	62
4.1.1.3. Função correlação cruzada .....	63
4.1.2. Correspondência por mínimos quadrados .....	63
4.2. Correspondência por assinatura.....	70
4.2.1. Determinação da discrepância entre as assinaturas .....	72
4.3. Outras técnicas para o reconhecimento de padrões .....	75

### **CAPÍTULO V**

5. MATERIAIS E MÉTODOS .....	79
5.1. Materiais.....	79
5.2. Métodos.....	80
5.2.1. Geração de padrões .....	81
5.2.2. Coleta de dados .....	83
5.2.3. Limiarização local .....	85

5.2.4. Segmentação .....	87
5.2.5 Classificação .....	88
5.2.5.1 Correlação .....	90
5.2.5.2 Assinatura .....	92
5.2.6. Localização precisa .....	95
5.2.6.1. Método de correspondência de imagens por mínimos quadrados e reamostragem .....	95
5.2.6.2. Detecção de cantos.....	97
5.2.7. Critério para avaliação do método de localização precisa .....	98

## **CAPÍTULO VI**

6. DESENVOLVIMENTO E IMPLEMENTAÇÃO.....	100
6.1. <i>Geração automática de padrões</i> .....	100
6.2. <i>Limiarização local</i> .....	102
6.3. <i>Segmentação</i> .....	105
6.4. <i>Classificação</i> .....	106
6.4.1. Correspondência por correlação.....	107
6.4.4.1. Comparação dos alvos segmentados com os padrões pré-definidos e com as suas instâncias armazenadas.....	108
6.4.4.2. Comparação dos alvos segmentados com os padrões pré-definidos suavizados e com as suas instâncias suavizadas armazenados .....	112
6.4.4.3. Comparação dos alvos segmentados com os padrões pré-definidos reamostrados .....	113
6.5. <i>Localização precisa</i> .....	125
6.5.1. Correspondência de imagens por mínimos quadrados.....	125
6.5.2. Detecção de cantos .....	127

## **CAPÍTULO VII**

7. CONCLUSÕES E RECOMENDAÇÕES.....	133
REFERÊNCIAS BIBLIOGRÁFICAS .....	135

## LISTA DE SIGLAS

<b>A/D</b>	Analógico/Digital
<b>AMD</b>	<i>Advanced Micro Devices</i>
<b>CC</b>	Calibração de câmaras
<b>CCD</b>	<i>Charge Coupled Device</i> – Dispositivo de carga acoplada
<b>DC</b>	Detector de cantos
<b>DPI</b>	<i>Dots per inch</i> – Pontos por polegadas
<b>EMQ</b>	Erro médio quadrático
<b>FAPESP</b>	Fundação de Amparo à Pesquisa do Estado de São Paulo
<b>FCT</b>	Faculdade de Ciências e Tecnologia
<b>GB</b>	Gigabytes
<b>MB</b>	Megabytes
<b>MMQ</b>	Método dos mínimos quadrados
<b>MQ</b>	Mínimos quadrados
<b>NC</b>	Nível de cinza
<b>PPD</b>	Padrões pré-definidos
<b>PPP</b>	Pontos por polegadas
<b>PR</b>	Padrões reamostrados
<b>RAM</b>	Random Access Memory – Memória de acesso aleatório
<b>UNESP</b>	Universidade Estadual Paulista
<b>UPTK</b>	Unesp Photogrammetric ToolKit

## **CAPÍTULO I**

### **1. INTRODUÇÃO**

#### **1.1. Considerações iniciais**

Atualmente, a reconstrução tridimensional é um dos assuntos mais abordados na literatura relacionada à Fotogrametria Digital e a Visão Computacional.

Há diversos sistemas para reconstrução 3D no mercado, porém, apresentam algumas das desvantagens: alto custo, necessidade de operadores altamente qualificados, impossibilidade de resposta em tempo real em curto período de tempo e dificuldade de reconstrução em superfícies com texturas homogêneas.

Pensando nestas desvantagens, decidiu-se criar um sistema que possuísse as seguintes características: baixo custo e facilidade de operação com alto grau de automação. Dos vários sistemas de reconstrução pesquisados, aqueles cujas características mais se aproximam destes requisitos são os sistemas de reconstrução por luz estruturada. Neste tipo de sistema utiliza-se uma fonte de luz, que projeta um padrão de luz conhecido na cena medida.

Inicialmente, um sistema de reconstrução composto por uma câmara digital Kodak DC 40 e um projetor de padrões foi construído. Os padrões projetados para este sistema eram brancos e circulares. A identificação automática para estes alvos é fácil, porém, nos objetos de superfícies com relevo muito irregular ocorreram

oclusões de alguns alvos, acarretando em incorretas identificações (TOMMASELLI, 1997). Uma solução para este problema de oclusão de padrões foi usar padrões coloridos com três diferentes formas, porém, em superfícies coloridas, alguns alvos ficaram oclusos dificultando na sua identificação (SCALCO, 2000).

Observando estes inconvenientes em trabalhos anteriores, resolveu-se usar padrões brancos com cinco diferentes formas neste trabalho. Além disso, um sistema formado por uma câmara de maior resolução foi criado para a captura da imagem em substituição à câmara anterior.

Como a reconstrução tridimensional é uma etapa muito complexa, dividiu-se o processo em duas etapas: reconstrução 3D e reconhecimento de padrões. A etapa em que consiste esta dissertação objetiva encontrar um método apropriado para a identificação e a medição automática de alvos, em uma ou mais imagens, procedimento fundamental na reconstrução. As vantagens da automação destes processos são: processos fotogramétricos mais flexíveis, maior agilidade e menor possibilidade de ocorrer erros grosseiros uma vez que é menor a intervenção do operador. Além disto, alguns métodos permitem, ainda, a medição das coordenadas com precisão subpixel.

Para a identificação e medição de alvos, um dos métodos mais utilizados é a correspondência por padrão (*template matching*). Achar um padrão na imagem vincula detecção (métodos de correlação cruzada e correlação baseada em feições), localização precisa (métodos baseados em áreas e métodos baseados em feições) e verificação. A correlação mede a similaridade de uma máscara de referência com uma janela de busca utilizando uma função de correlação adequada. Já a correlação por mínimos quadrados procura refinar esta correspondência pela estimação dos parâmetros de transformação radiométricos e geométricos entre as

janelas de referência e de pesquisa, de acordo com o critério dos mínimos quadrados. Esses métodos baseados em área são sensíveis ou afetados por problemas como:

- Iluminação não adequada;
- Distorção dos padrões;
- Ruídos;
- Tamanho da janela de referência; e,
- Grande número de janelas de referência a serem comparadas.

Por estes problemas mencionados acima, resolveu-se comparar os métodos de classificação por correlação com o método de assinatura e o método de localização precisa por mínimos quadrados com os por detector de cantos.

A assinatura é um método de correspondência que consiste na comparação da representação funcional unidimensional de uma fronteira. Há várias maneiras de se adquirir uma assinatura. Uma das mais fáceis de obtê-la é a partir do gráfico da distância da fronteira do alvo ao centróide em função da direção. Esta assinatura não varia em relação à translação, mas depende da rotação e mudança de escala (GONZALES e WOODS, 2000). A eficácia deste processo depende dos operadores que são utilizados para a etapa de extração de feições.

A detecção de cantos, neste trabalho, é obtida pela combinação de dois operadores: Moravec e Förstner. O operador de Moravec gera coordenadas com precisão *pixel* que são posteriormente usadas como coordenadas aproximadas para a determinação subpixel das coordenadas com o operador de Förstner.

Os experimentos são apresentados e discutidos, mostrando as vantagens e desvantagens de cada metodologia, além de indicar o método mais eficaz para a detecção e localização precisa para os tipos de alvos usados.

## **1.2. Objetivos**

### *1.2.1. Objetivo geral*

Este trabalho tem como objetivo o estudo e o desenvolvimento de métodos de classificação e de localização automáticos de alvos em imagens tomadas à curta-distância usando o sistema de luz estruturada.

### *1.2.1. Objetivos específicos*

- ✓ Implementar programas relacionados aos métodos de reconhecimento e localização automáticos de alvos em imagens tomadas à curta-distância:
  - Geração automática de padrões para criação de fotolitos, os quais serão projetados na cena desejada, usando o sistema de luz estruturada;



- Limiarização local da imagem;
  - Segmentação da imagem por crescimento de regiões;
  - Determinação da fronteira pelo método de perseguição de fronteiras;
  - Assinatura;
  - Correspondência por correlação;
  - Correspondência por mínimos quadrados.
- ✓ Realizar experimentos para comparação dos resultados:
- Comparação dos métodos de correlação e de assinatura para a detecção automática dos alvos projetados;
  - Comparação dos métodos de mínimos quadrados e de detector de cantos para a localização automática precisa dos alvos;
  - Análise dos métodos a partir da comparação das discrepâncias dos dados a partir de uma reconstrução.
- ✓ Integração à biblioteca de classes e de funções UPTK (**Unesp Photogrammetric ToolKit**) desenvolvida no Departamento de Cartografia.

### **1.3. Estrutura do trabalho**

Este trabalho é composto de sete capítulos. No primeiro capítulo apresenta-se uma abordagem geral sobre algumas técnicas empregadas e os seus problemas para realização do reconhecimento automático de alvos.

No segundo capítulo, efetua-se uma revisão a respeito de imagens digitais e os conceitos envolvidos em sua aquisição.

No capítulo seguinte, é feita uma revisão a respeito da Fotogrametria à curta distância, suas aplicações, além de enfatizar o método ativo denominado luz estruturada.

No quarto capítulo são revisados alguns métodos de detecção e de localização precisa utilizados no trabalho.

No quinto capítulo são apresentados os materiais utilizados no desenvolvimento do trabalho, bem como os métodos desenvolvidos e implementados.

O sexto capítulo descreve o desenvolvimento, a implementação e os experimentos realizados da metodologia discutida anteriormente.

O sétimo capítulo traz as considerações finais e as recomendações para os futuros trabalhos nesta área de pesquisa.

## CAPÍTULO II

### 2. IMAGENS DIGITAIS: AQUISIÇÃO E PROCESSAMENTO

#### 2.1. Imagem Digital

Segundo Schenk (1999), imagem é uma função contínua  $F(x, y)$  na qual as coordenadas  $x, y$  são as variáveis espaciais e o valor da função são os níveis de cinza. A discretização desta função resulta na imagem digital com uma função discreta  $f(x, y)$ .

A qualidade de uma imagem depende de dois fatores:

- Resolução espacial: relacionada com o tamanho do *pixel* e é freqüentemente expressa em ppp (pontos por polegadas; dpi - *dots per inch*). Na Tabela 1 pode-se observar a dimensão do *pixel* para diferentes resoluções.

TABELA 1 – Resolução espacial.

ppp	300	600	1200	1270	2540
Tamanho do <i>pixel</i> ( $\mu\text{m}$ )	84	42	21	20	10

- Resolução radiométrica: Depende dos níveis de quantização (transformação da função contínua em valores de cinza discretos)

empregados. A Tabela 2 mostra o número de bits necessários para representar certos níveis de cinza.

TABELA 2 – Resolução radiométrica.

n	Bits	1	2	3	4	5	6	7	8
$2^n$	Níveis de cinza	2	4	8	16	32	64	128	256

## 2.2. Câmaras digitais

Segundo Tommaselli et al (2000), câmaras digitais são dispositivos compostos de um sistema de lentes, um chip sensor, que pode ser do tipo CCD (*Charge Coupled Device*) ou CMOS (*Complementary Metal Oxide Semiconductor*), processadores e uma memória para a coleta e armazenamento de imagens digitais. O princípio de formação de uma imagem digital pode ser observado na Figura 1.

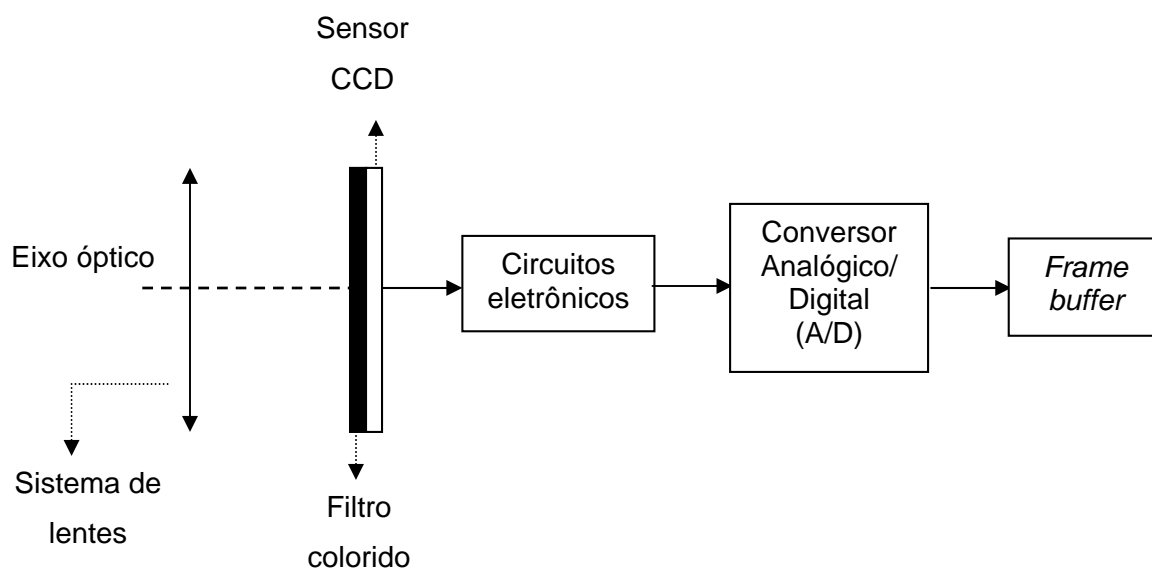


FIGURA 1 - Princípio de formação de uma imagem digital.

(Adaptado de TOMMASELLI et al, 2000)

O conversor A/D possui como objetivo transformar o sinal elétrico analógico gerado pelo CCD em um sinal digital, que é armazenado em uma memória temporária (*frame buffer*).

### 2.3. Sistemas de coordenadas

O sistema de coordenadas de uma imagem digital é um sistema plano-retangular com origem no canto superior esquerdo, sendo o eixo das abscissas coincidente com a primeira linha e o eixo das ordenadas com a primeira coluna (Figura 2).

Para realização de procedimentos fotogramétricos com as imagens digitais, utiliza-se um sistema intermediário  $(x, y)$  com origem definida no centro da imagem (Figura 2).




FIGURA 2 – Definição do sistema de coordenadas de uma imagem digital.

A transformação das coordenadas do sistema imagem para o sistema intermediário depende de uma translação entre as origens dos sistemas, uma reflexão no eixo das ordenadas e um fator de escala equivalente ao tamanho do *pixel*, a fim de estabelecer as coordenadas num sistema métrico (Equação 1).

$$\begin{aligned}x &= (j - c_x) * S_x \\ y &= -(i - c_y) * S_y\end{aligned}\tag{1}$$

Onde:

$$c_x = \frac{W - 1}{2}$$

$$c_y = \frac{H - 1}{2}$$

$x, y$  – coordenadas referidas ao sistema intermediário;

$i, j$  – coordenadas referidas ao sistema da imagem;

$c_x, c_y$  - coordenadas do centro da imagem no sistema de imagem;

$H, W$  – números de linhas e colunas, respectivamente;

$S_x, S_y$  – dimensões do *pixel* nas componentes x e y, respectivamente.

## 2.4. Efeitos sistemáticos

No processo de formação de uma imagem digital, há efeitos sistemáticos que produzem distorções, com causas e características distintas. Estes

efeitos ocorrem com frequência e podem ser modelados matematicamente, a fim de que se possam minimizar os efeitos de afastamento da geometria projetiva.

Alguns dos efeitos sistemáticos existentes na formação das imagens digitais, segundo Galo (1993) e Mikhail et al (2001) são:

- Deslocamento do ponto principal;
- Distorção das lentes.

O deslocamento do ponto principal ocorre pela não coincidência do eixo óptico com o centro da imagem.

Segundo Mikhail et al (2001), a distorção das lentes é a aberração mais relevante para a prática fotogramétrica. Estas distorções são causadas pelos desvios dos raios que, ao atravessar em um sistema de lentes, prejudicam a geometria por meio de deslocamentos na imagem. Esta aberração pode ser dividida em: distorção radial simétrica e distorção descentrada.

A distorção radial simétrica é o deslocamento radial de um ponto na imagem, isto é, uma mudança no ângulo entre o raio de luz e o eixo óptico sofrida por um raio de luz ao atravessar uma lente ou um sistema de lentes (MIKHAIL et al, 2001).

A distorção descentrada é um deslocamento da imagem advindo da impossibilidade do fabricante em alinhar perfeitamente os eixos ópticos das lentes de uma objetiva.

## 2.5. Melhoria de contraste linear

O melhoria de contraste linear consiste no processamento de uma imagem, de modo que o resultado seja mais apropriado para uma aplicação específica do que a imagem original. O contraste nas imagens é afetado pela iluminação não homogênea e abertura incorreta do diafragma da câmara durante a aquisição da imagem. É normalmente usado como uma etapa de pré-processamento para sistemas de reconhecimento de padrões (GONZALES e WOODS, 2000).

Dentre os métodos existentes para solucionar este problema encontram-se: método denominado expansão do histograma, método de contraste linear percentual e método de transformação local.

### 2.5.1. Método de expansão do histograma

Este método de melhoria ocupa todo o intervalo de cinza, não provocando nenhuma perda. Esta operação é realizada a partir de uma interpolação linear (Equação 2) (SPRING, 2003).

$$G_t = \left( \frac{G_i - G_{\min}}{G_{\max} - G_{\min}} \right) * maior\_nivel \quad (2)$$



Onde:

$G_{\min}$  – menor nível de cinza encontrado na imagem;

$G_{\max}$  – maior nível de cinza encontrado na imagem;

$G_i$  – nível de cinza original de um *pixel* na imagem;

$G_t$  – nível de cinza resultante de um *pixel* após a transformação;

*maior\_nível* – indica o maior nível de quantização disponível. Por exemplo: se a imagem possui 8 bits, o maior nível é dado por  $2^8 - 1 = 255$ .

Outra forma de melhoramento do contraste é denominada de contraste linear percentual. Este processo é utilizado quando se deseja especificar os valores de  $G_{\min}$  e  $G_{\max}$  para realçar determinado intervalo de cinza. Neste caso, utiliza-se uma certa percentagem de *pixels* a partir da média do histograma. O problema deste processo é a perda de informação em benefício do realce da informação que se deseja realçar. Além disso, como escolher a percentagem de *pixels* a se trabalhar porque depende da imagem original (GONZALES e WOODS, 2000).

### 2.5.2. Transformação local

Os métodos mostrados na Seção 2.4.1 são globais no sentido de que os *pixels* são modificados através de uma função de transformação baseada na distribuição dos níveis de cinza sobre uma imagem inteira, não garantindo o realce local desejado. Uma transformação local baseada nas propriedades de intensidades

da média e do desvio-padrão de *pixels* pode ser observada na Equação 3 (GONZALES e WOODS, 2000).

$$g(x, y) = A(x, y)[f(x, y) - m(x, y)] + m(x, y) \quad (3)$$

Onde:

$$A(x, y) = kM / \sigma(x, y);$$

$f(x, y)$  - níveis de cinza da imagem original;

$g(x, y)$  - níveis de cinza da imagem resultante;

$m(x, y)$  - nível de cinza médio calculado numa vizinhança centrada em  $(x, y)$ ;

$\sigma(x, y)$  - desvio-padrão calculado numa vizinhança centrada em  $(x, y)$ ;

$M$  - média global de  $f(x, y)$ ;

$k$  - constante variando no intervalo  $[0,1]$ .

Este método possui um melhor resultado em relação ao método de expansão do histograma pelo fato de realizar um melhoramento local, porém, possui uma desvantagem na automação do processo, já que, a constante  $k$  a ser sugerida depende das características da imagem original.

## 2.6. Segmentação

A segmentação consiste em subdividir uma imagem em regiões homogêneas usando propriedades desejadas como: nível de cinza, cor ou textura. Os principais objetivos da segmentação são reduzir a quantidade de dados a serem processados na análise de imagens e obter importantes informações a respeito de objetos e feições contidas nelas (EL-HAKIM, 1996).

Os métodos de segmentação podem ser divididos em dois tipos: baseados em bordas e baseados em regiões (SONKA et al, 1998).

Os métodos de segmentação baseados em bordas procuram discriminar os objetos pelos contornos detectados a partir das discontinuidades em algumas das propriedades. O problema deste método está no fato de não haver *pixels* com valores de gradientes nulos, resultante de ruídos ou variações de iluminação.

Os métodos de segmentação baseados em regiões procuram dividir a imagem em regiões que devem corresponder às áreas de interesse da aplicação. Estas regiões consistem no conjunto de *pixels* contíguos que se espalham bidirecionalmente e que apresentam uniformidade (SPRING, 2003). O método mais conhecido para este tipo de segmentação é o crescimento de regiões. Este método consiste em agrupar *pixels* vizinhos que apresentam regiões homogêneas segundo critérios de similaridade. Um dos critérios que pode ser usado é comparar se a média e o desvio-padrão dos níveis de cinza de duas regiões e verificar se estes valores são estatisticamente compatíveis.

Para o reconhecimento de padrões, a etapa de segmentação é interessante porque não necessita que cada alvo armazenado percorra toda a imagem comparando os níveis de cinza, otimizando o processo, evitando diferentes respostas para o mesmo tipo de alvo e proporcionando resultados mais confiáveis.

## 2.7. Limiarização

Segundo Gonzales e Woods (2000), a etapa de limiarização é uma das abordagens mais importantes para a segmentação de imagens.

A limiarização pode ser resolvida a partir de técnicas globais e locais. As técnicas globais consistem em determinar um único limiar para toda a imagem. A escolha da modificação dos níveis de cinza depende da significância do objeto na imagem. Isto é, caso o objeto significativo possua valores de níveis de cinza altos, todos os valores acima do limiar permanecem com o nível de cinza original e abaixo deste limiar recebem zero.

Porém, esta técnica traz problemas causados pela reflectância, sombras e iluminação não adequada. O sucesso deste método depende de um histograma bimodal.

Uma das maneiras de determinar o limiar ( $T$ ) é a partir da média ( $m$ ) e do desvio-padrão ( $s$ ) dos níveis de cinza da imagem, a partir da Equação 4.

$$T > m + 3s \quad (4)$$

Uma melhor alternativa, portanto, são as técnicas locais, que consistem em determinar um limiar para cada região da imagem, que pode ser delimitada por uma janela.

Outras técnicas destinadas à obtenção de um valor de limiar são descritas resumidamente nas seções seguintes. Para maiores detalhes ver Sonka et al (1998) e Artero (1999).

### 2.7.1. Método de Otsu

O método de Otsu é baseado na análise discriminante e o valor do limiar é obtido supondo que os *pixels* da imagem podem ser classificados em duas classes: fundo ( $C_1$ :níveis de cinza no intervalo  $[1, t]$ ) e objeto ( $C_2$ :níveis de cinza no intervalo  $[t + 1, L]$ ) (OTSU, 1979). Neste caso, a distribuição de probabilidade de ambas as classes podem ser descritas por:

$$C_1 : \frac{p_1}{\omega_1(t)}, \dots, \frac{p_t}{\omega_1(t)} \quad \text{e} \quad C_2 : \frac{p_{t+1}}{\omega_2(t)}, \dots, \frac{p_L}{\omega_2(t)} \quad (5)$$

Onde:

$$\omega_1(t) = \sum_{i=1}^t p_i \quad \text{e} \quad \omega_2(t) = \sum_{i=t+1}^L p_i$$

As médias para as classes  $C_1$  e  $C_2$  são dadas por:

$$\mu_1 = \sum_{i=1}^t \frac{i \cdot p_i}{\omega_1(t)} \quad \text{e} \quad \mu_2 = \sum_{i=t+1}^L \frac{i \cdot p_i}{\omega_2(t)} \quad (6)$$

Sendo  $\mu_T$  a intensidade média para toda a imagem, então:

$$\omega_1(t)\mu_1 + \omega_2(t)\mu_2 = \mu_T \quad (7)$$

e

$$\omega_1(t) + \omega_2(t) = 1 \quad (8)$$

Utilizando a análise discriminante, a variância entre as classes da imagem limiarizada é definida por:

$$\sigma_B^2 = \omega_1(t)(\mu_1 - \mu_2)^2 + \omega_2(t)(\mu_2 - \mu_1)^2 \quad (9)$$

O limiar ótimo  $t^*$  é determinado como sendo aquele cuja variância entre as classes  $\sigma_B^2$  é máxima, isto é:

$$t^* = \arg \max \{ \sigma_B^2(t) \}, 1 \leq t \leq L \quad (10)$$

### 2.7.2. Método de Pun

O método de Pun está relacionado com a teoria da informação, que se baseia na premissa de que a geração de informação pode ser modelada como um processo probabilístico (GONZALES, 1993).

A partir desta teoria, define-se a entropia da imagem como:

$$Entropia(x) = x \cdot \log(x) \quad (11)$$

Como neste método pretende-se segmentar em duas classes (fundo e objeto), têm-se duas entropias (Equação 12).

$$H_b = - \sum_{i=0}^t p_i \log_e p_i \quad (12)$$

$$H_w = - \sum_{i=t+1}^{l-1} p_i \log_e p_i$$

O limiar, neste método, é obtido por:

$$T = ArgMaximo\{H_b(t) + H_w(t)\} \quad (13)$$

### 2.7.3. Limiarização local

Artero (1999) utilizou uma técnica de limiarização local da imagem que consiste em determinar um limiar utilizando os *pixels* pertencentes a uma janela de 60 *pixels* x 60 *pixels*. O valor de limiar assim obtido é utilizado para todos os *pixels* localizados na região central desta janela (uma região de tamanho 20 *pixels* x 20 *pixels*). As dimensões destas janelas foram definidas empiricamente e podem ser alteradas dependendo das características da imagem.

Como algumas regiões não possuem todos os blocos vizinhos, algumas alterações devem ser realizadas no momento da implementação. No total, são nove regiões da borda da imagem que necessitam ser diferenciada em relação ao tamanho da máscara a ser percorrida e a região que será alterada pelo limiar determinado (Figura 3).

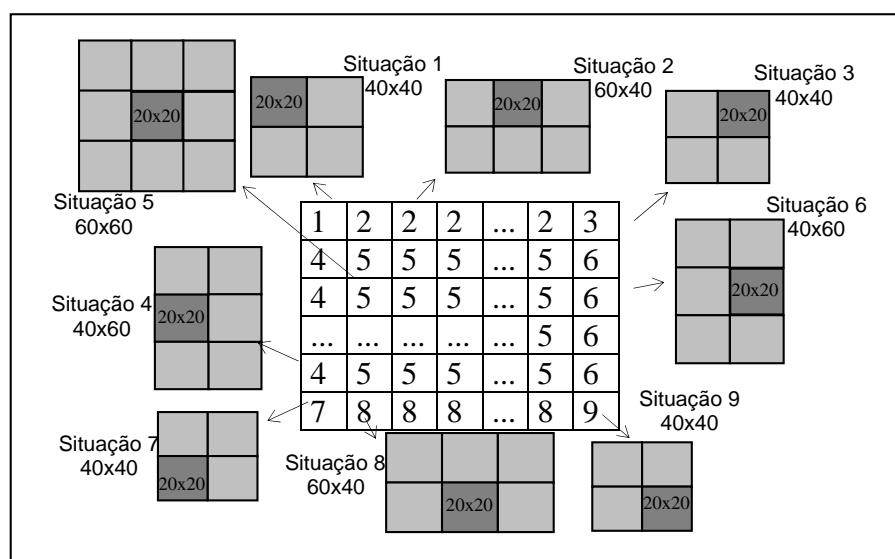


FIGURA 3 – Regiões definidas no processo de limiarização local.

(Fonte: ARTERO, 1999).



## 2.8. Detecção de bordas

A etapa de detecção de bordas é essencial para o cálculo das coordenadas subpixel. Este método consiste na aplicação de um detector de bordas, que normalmente é baseado na aplicação de operações de detecção de variações de brilho na imagem. Para a detecção de bordas, os operadores de gradiente são imprescindíveis. Estes gradientes são apresentados a seguir.

### 2.8.1. Operadores de gradiente

Segundo Gonzales e Woods (2000), o gradiente ( $\nabla f$ ) de uma imagem  $f(x, y)$  na posição  $(x, y)$  é dado pelo vetor na Equação 14.

$$\nabla f = \begin{bmatrix} G_x \\ G_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix} \quad (14)$$

Onde:

$G_x, G_y$  – gradientes em x e y, respectivamente.

Nos métodos de detecção de bordas, a magnitude deste vetor é muito importante porque o alto valor da magnitude indica a presença de bordas, isto

é, uma grande variação entre os níveis de cinza na imagem. A magnitude deste vetor é obtida pela raiz quadrada da soma dos quadrados dos gradientes em x e y (Equação 15).

$$\nabla f = \sqrt{(G_x)^2 + (G_y)^2} \quad (a) \quad (15)$$

$$\nabla f = |G_x| + |G_y| \quad (b)$$

Outro valor importante na detecção de bordas é a direção do vetor ( $\alpha$ ) para cada *pixel* em relação ao eixo x. Este ângulo é determinado pela Equação 16.

$$\alpha = \arctg\left(\frac{G_y}{G_x}\right) \quad (16)$$

A representação geométrica das grandezas calculadas nas Equações 15a e 16 pode ser percebida por meio da Figura 4.




FIGURA 4 – Representação das magnitudes dos gradientes e do ângulo de direções das bordas.

### 2.8.1.1. Operadores de Sobel

O operador de Sobel é definido com valores maiores na parte central das máscaras, o que equivale, considerar que os *pixels* centrais têm uma maior influência em relação aos *pixels* das bordas. Os gradientes são determinados a partir de duas máscaras representando os gradientes em x e y. Estas máscaras podem ser observadas na Figura 5.

-1	0	1
-2	0	2
-1	0	1

(a)

-1	-2	-1
0	0	0
1	2	1

(b)

FIGURA 5 – Máscaras usadas no operador de Sobel.

(a) Gradiente em x; (b) Gradiente em y.

Uma vantagem do operador de Sobel em relação a outros operadores de gradiente é conseguir detectar bordas em qualquer direção.

A detecção de bordas, neste método, consiste em realizar a convolução das máscaras na imagem desejada. Para cada convolução, determinam-se os gradientes em x e y para o *pixel* central. No final do procedimento, a imagem resultante dos gradientes possui o mesmo tamanho da imagem original. Como em cada convolução, os gradientes em x e y são determinados apenas para os *pixels* centrais, uma implementação utilizando-se as vizinhanças parciais é necessária para determinar os gradientes nas bordas da imagem.

## 2.9. Detector de cantos

### 2.9.1. Operadores de interesse

Os operadores de interesse podem ser definidos como um operador de vizinhança que objetiva localizar com uma alta precisão as coordenadas *pixel* ou subpixel (HARALICK e SHAPIRO (1993) apud GALO e TOZZI (2002)). Dentre os diversos operadores de interesse pode-se citar: operador de Moravec e operador de Förstner.

#### 2.9.1.1. Operador de Moravec

Este operador baseia-se na medida de variância direcional considerando os quadrados das diferenças de tons de cinza em quatro direções: 0°, 45°, 90° e 135° (Figura 6).

Levando-se em conta uma janela com  $n \times n$  *pixels* e admitindo que o elemento inteiro  $(n/2, n/2)$  é o *pixel* central, pode-se obter a resposta do operador de interesse Moravec pelo cálculo das equações 17.




FIGURA 6 - Janelas 3x3 mostrando os vetores de 0°, 45°, 90° e 135°, respectivamente (GALO e TOZZI, 2002).

$$OI[r][c] = \min \begin{cases} V_{0^\circ} = \frac{1}{n(n-1)} \sum_{r=0}^{2N} \sum_{c=N}^{2N} (g(r, c) - g(r, c-1))^2 \\ V_{45^\circ} = \frac{1}{(n-1)^2} \sum_{r=0}^N \sum_{c=N}^{2N} (g(r, c) - g(r+1, c-1))^2 \\ V_{90^\circ} = \frac{1}{n(n-1)} \sum_{r=0}^N \sum_{c=0}^{2N} (g(r, c) - g(r+1, c))^2 \\ V_{135^\circ} = \frac{1}{(n-1)^2} \sum_{r=0}^N \sum_{c=0}^N (g(r, c) - g(r+1, c+1))^2 \end{cases} \quad (17)$$

Onde:

$r, c$  - linhas e colunas da imagem, respectivamente;

$g(r, c)$  - níveis de cinza para posição  $(r, c)$ ;

$N = (n-1)/2$ ; e,

$OI$  – operador de interesse.

A Equação 17 determina, para cada ponto da imagem, o valor mínimo do operador de interesse nas quatro direções. A partir do valor do operador de interesse obtido na Equação 17, para cada ponto da imagem, os máximos locais de  $OI[r][c]$  podem ser encontrados. Pixels com valores de  $OI[r][c]$  superiores a um

limiar pré-estabelecido correspondem a pontos de quina. O resultado deste operador serão as coordenadas dos cantos com precisão *pixel*.

Vale ressaltar que o uso de janelas de dimensão ímpar (Equação 17) não é uma restrição do operador de Moravec, mas uma opção de Galo e Tozzi (2002). Esta restrição deve ao fato de se ter escolhido o *pixel* central da janela como origem, sendo a janela simétrica a este ponto.

#### 2.9.1.2. Operador de Förstner

Para determinação da posição das quinas com acurácia subpixel pode-se usar o fato de que uma quina é formada pela intersecção de pelo menos dois segmentos lineares, isto é, a quina é localizada pela intersecção dos vetores perpendiculares às direções de máximo gradiente sobre as bordas.

Um dos operadores mais usados para detecção de quinas (operadores de interesse) é o operador de Förstner.

As coordenadas destes operadores de interesse (cantos) são determinadas com precisão subpixel usando a Equação 18. (FÖRSTNER, 1988 apud GALO e TOZZI, 2002).

$$\begin{bmatrix} L_0 \\ C_0 \end{bmatrix} = \begin{bmatrix} \sum g_{Li}^2 & \sum g_{Li}g_{Ci} \\ \sum g_{Li}g_{Ci} & \sum g_{Ci}^2 \end{bmatrix}^{-1} \begin{bmatrix} \sum (L_i g_{Li}^2 + C_i g_{Li}g_{Ci}) \\ \sum (C_i g_{Ci}^2 + L_i g_{Li}g_{Ci}) \end{bmatrix} \quad (18)$$

Onde:

$L_0, C_0$  - coordenadas dos cantos com precisão subpixel;

$L_i, C_i$  - coordenadas do *pixel* de uma janela  $m \times m$ ;

$g_{Li}, g_{Ci}$  - gradientes em y e x, respectivamente.

Como pode ser observado na Equação 18, a estimação da posição dos cantos com precisão subpixel depende das posições com precisão *pixel* e os gradientes ao longo das linhas e colunas. Os gradientes em x e y podem ser determinados a partir dos operadores de Sobel (Seção 2.7.1.1).

A matriz inversa 2 x 2 na Equação 18 pode ser vista como a matriz variância-covariância do ajustamento. Esta matriz pode ser usada para obter a elipse dos erros associada à quina  $(L_0, C_0)$  e fazer a discriminação de pontos com diferentes características (HARALICK e SHAPIRO, 1993 apud GALO e TOZZI, 2002).

### 2.9.2. Técnica híbrida usada para detecção de cantos

Galo e Tozzi (2002) desenvolveram um método para a extração de pontos com acurácia subpixel em imagens digitais usando uma combinação dos métodos de detecção de quinas: Moravec e Förstner. Primeiramente, detectam-se os cantos usando o operador de Moravec com precisão *pixel* que são usados, posteriormente, como pontos iniciais para obtenção das coordenadas de cantos subpixel. Esta etapa é realizada normalizando a matriz dos valores de OI (Equação 17) no intervalo  $[0,255]$  e fazendo-se a supressão dos não máximos aplicando-se um certo limiar que pode ser expresso de modo percentual ( $T_p$ ). Os *pixels* com níveis de

cinza superiores ao limiar ( $Lim(T_p)$ ) determinado são rotulados como *pixels* prováveis de serem de quinas.

$$Lim(T_p) = (100 - T_p) * \frac{255}{100} \quad (19)$$

Com esta segmentação, a imagem original fica subdividida em duas classes. Como em torno das quinas tem-se um conjunto de pontos, podem-se agrupar estes pontos e usar o centro de massa destas regiões como posições aproximadas das quinas. O centro de massa de cada região é então rotulado como 255 e, portanto, tem-se como resultado uma imagem composta de três classes. Estes *pixels* com rótulos iguais a 255 são usados como centro da janela a ser selecionada para o cálculo das coordenadas subpixel usando o operador de Förstner (Seção 2.8.1.2). Um cuidado a ser tomado, neste procedimento, está relacionado ao tamanho da janela a ser selecionada para determinação dos gradientes em x e y. Caso a janela a ser selecionada seja muito pequena, a localização precisa torna-se precária; porém, se a janela for muito grande também, pode-se capturar dados que não façam parte do canto a ser determinado, deteriorando os resultados. Outro cuidado que merece atenção é o fato de se usar limiar global para a supressão dos não máximos. Uma solução para evitar que quinas em regiões de baixo contraste sejam selecionadas é realizar todos os procedimentos em áreas locais selecionadas da imagem.

Outro problema existente é advindo da aquisição da imagem, acarretando em cantos arredondados e dificultando na intersecção das retas.



## CAPÍTULO III

### 3. FOTOGRAMETRIA À CURTA DISTÂNCIA

Fotogrametria terrestre é o ramo da Fotogrametria realizada com fotografias obtidas com câmaras situadas na superfície terrestre. Um caso especial da Fotogrametria terrestre, com fotografias tiradas até uma distância de 100 m, é denominado de Fotogrametria à curta distância (WOLF, 1983).

Um método alternativo deste ramo da Fotogrametria e muito utilizado para a identificação e medição automática de superfícies é o método ativo denominado luz estruturada. Este método possui como objetivo substituir uma das câmaras por uma fonte de luz, facilitando no processo de determinação de correspondência.

#### 3.1. Aplicações da Fotogrametria à curta distância

As aplicações da Fotogrametria à curta distância encontram-se, principalmente, nas seguintes áreas:

- Indústria: Os principais setores envolvidos, de acordo com Fraser (1996), englobam a fabricação de aeronaves e automóveis, as

indústrias aeroespaciais, químicas e nucleares e o controle de qualidade da produção.

Peipe e Schneider (1995) apud Fraser (1996) aplicaram um sistema denominado DPA-Win VM para inspeção das ferramentas de produção automotiva (Figura 7). A tarefa envolveu a medida de 30 suportes, os quais foram sinalizados com quatro alvos para obtenção dos parâmetros de orientação e posição. Uma rede composta de 40 câmaras foi necessária para obter a cobertura total dos alvos para uma imagem com escala 1:50 e maior. A acurácia obtida após a triangulação por feixes de raios foi de 0.05 mm ou 1:70.000.



FIGURA 7 - Ferramenta de produção automotiva (PEIPE e SCHNEIDER (1995) apud FRASER (1996)).

- Medicina: Utilizada na reconstrução e na determinação de formas e dimensões de órgãos e membros do corpo humano, inclusive com uso de ondas eletromagnéticas em outras faixas do espectro que abrange o visível, como por exemplo, os raios-X.

Wong et al (1992) apud Newton e Mitchell (1996) empregaram métodos fotogramétricos para estudar o crescimento e a distribuição de massa corporal. A cobertura completa foi obtida através de nove câmaras digitais agrupadas 3 a 3. Cada conjunto de 3 câmaras formava um triângulo com distância de 2 m do paciente.

- Arquitetura: Utilizada na representação de fachadas ou elevações de monumentos históricos e estruturas.

Segundo Dallas (1996), um exemplo de aplicação é o levantamento da igreja St. Mary, North Yorkshire, realizado em 1994 pela agência governamental responsável pela preservação e gerenciamento de aproximadamente 400 monumentos na Inglaterra denominada English Heritage. Nesta igreja, foi realizada uma cobertura estéreo, tanto na porção interior como exterior utilizando a câmara UMK 30/1318 da Zeiss.

- Arqueologia: Utilizada na reconstrução de objetos arqueológicos e achados de sítios arqueológicos.

Segundo Dallas (1996), um exemplo desta aplicação foi à tomada de fotos do navio Romano-Celta, encontrado próximo a Magor, a partir da câmara Wild P31. No total, 15 fotografias foram necessárias.

Hasegawa et al (1999) descreveram uma metodologia para determinação das coordenadas dos achados arqueológicos ao longo da margem do Rio Paraná. As tomadas fotográficas realizadas nas trincheiras eram quase na vertical e ocupavam geralmente uma área de um metro quadrado. A câmara usada

para este trabalho foi uma Kodak DC210. A etapa de reconstrução do objeto foi realizada usando as equações de colinearidade.

### **3.2. Luz estruturada**

Segundo Battle et al (1996), a percepção de profundidade é uma das etapas mais importantes da Visão Computacional. A necessidade de conhecer informações 3D a respeito da superfície pode ser resolvida a partir de métodos passivos ou ativos, como já foi mencionado. Dentre os métodos ativos encontra-se a técnica denominada de luz estruturada.

Segundo Newton e Mitchell (1996), esta técnica envolve o uso de um projetor e uma câmara, no qual o sistema de projeção é usado para projetar o padrão sobre o objeto na cena e uma câmara captura a imagem dos padrões que são distorcidos pela superfície de projeção. O projetor é equivalente a segunda câmara usada na Fotogrametria e qualquer ponto projetado na cena com direção e com identificação conhecidas pode ser reconstruído usando os princípios de intersecção dos raios de luz da Fotogrametria analítica (relação câmara-projetor). A determinação das relações geométricas existentes entre o sensor e os feixes de raios luminosos dos padrões projetados é conseguida por uma calibração de sistema. O sistema de luz estruturada permite a reconstrução 3D para cada ponto de vista, sendo necessária à combinação de vários pontos de vistas para criar um modelo 3D completo do objeto. Uma das vantagens deste sistema é quando este usa fontes de luz branca e conseqüentemente, não há a necessidade de cuidados

especiais de segurança, ao contrário de sistemas de varredura a *laser*, cuja luz possui algum nível de radiação. Além disso, alguns sistemas de luz estruturada possuem precisões compatíveis com o sistema laser. Como vantagem deste sistema há a possibilidade de se capturar todos os alvos projetados e a imagem do objeto de uma só vez, não sendo necessário manter o objeto estático durante a aquisição. Também pode haver a necessidade de tomada de múltiplas posições para cobrir inteiramente um objeto, quando ele for maior que o campo de cobertura do sensor.

As vantagens deste sistema em relação a técnicas estereofotogramétricas estão relacionadas com (BATTLE et al, 1996):

- Menor tempo entre a tomada de fotos e a resposta final;
- Menor custo dos equipamentos;
- Não necessidade de pessoas especializadas para manusear os equipamentos; e,
- Menor dificuldade ao medir superfícies homogêneas.

### *3.2.1. Técnicas utilizando o sistema de luz estruturada*

Muitas são as formas de identificar e medir pontos conjugados ou correspondentes. A seguir, são descritas algumas técnicas para solucionar este problema, particularmente para sistemas à curta distância.

Ballard e Brown (1982) descreveram a técnica de luz estruturada, na qual a superfície é seccionada por um plano de luz e a cena é imageada continuamente, enquanto a fonte de luz faz a varredura de toda a superfície. A

vantagem é a simplificação do processo de extração de feições, uma vez que apenas uma linha aparece em cada imagem. O problema é a necessidade de imobilizar tanto o objeto quanto a câmara, durante o processo de aquisição de imagens.

Hummel e Carrihill (1985) desenvolveram um sistema baseado no conceito de J. T. Schwartz, onde se pode reconstruir a profundidade a partir de duas imagens sem necessidade de resolver o problema de correspondência. Este sistema utiliza-se do princípio de plano de luz para reconstrução da geometria 3D, onde um ponto objeto é determinado pela intersecção do plano vertical passando através do centro da lente do projetor e a linha de sinal determinada pela imagem da câmara. Este plano vertical é determinado de duas maneiras: com uma intensidade projetada uniformemente e com intensidades graduadas produzidas por um filtro linear.

Keefe e Riley (1986) utilizaram o princípio de luz estruturada para reconstrução 3D de formas faciais. Este sistema projeta uma linha de pontos verticais gerada por um laser. A partir de um estereopar das imagens da face é possível reconstruir um contorno de uma parte desta.

Wang et al (1987) introduziram uma abordagem para a determinação das orientações da superfície com luz estruturada, sem correspondência. Neste método, assume-se que a geometria da câmara e do projetor podem ser aproximada por uma projeção ortográfica. A função de calibração determina a orientação relativa do plano da imagem da câmara, o plano do slide e o plano base. Dois padrões ortogonais de faixas paralelas são projetados sobre a superfície do objeto. A orientação da superfície pode ser inferida das direções das faixas na imagem coletada pela câmara. Para cada padrão, uma injunção geométrica na orientação da superfície é obtida. Esta orientação pode ser obtida

pela intersecção das duas curvas na esfera gaussiana e interpoladas utilizando a interpolação bicúbica. Portanto, a profundidade relativa pode ser determinada da orientação da superfície a partir da integração de uma equação diferencial.

Boyer e Kak (1987) implementaram um esquema de código colorido que projeta um padrão de faixas verticais vermelhas, verdes, azuis e brancas sobre a cena. O padrão projetado possui diversos subpadrões chaves. O padrão chave pode ser localizado na imagem da câmara usando um conjunto de correlatores binários. A localização dos padrões chaves serve como semente para indexar as faixas vizinhas. Este método, como o de Scalco (2000), traz problemas pelo fato de utilizar alvos coloridos. Isto dificulta na identificação dos alvos se o fundo for colorido.

Dunn e Keizer (1989), usando luz estruturada, recuperaram a forma tridimensional de partes do corpo humano. Este sistema projeta uma grade quadrada de 35 mm que aparece distorcida na imagem coletada pela câmara devido à curvatura e a variação na orientação da superfície. As coordenadas 3D são determinadas pela intersecção das linhas da grade projetada seguida de uma triangulação. Este sistema realiza o processamento em quatro passos:

- Determinação das matrizes de calibração da câmara e do projetor;
- Processamento da imagem para localizar as interseções da grade na imagem da câmara;
- Rotulação da grade; e,
- Triangulação.

O padrão desenvolvido por Dunn e Keizer (1989) pode ser observado na Figura 8. Este padrão apresenta problemas quando se trabalha com

superfícies com descontinuidades porque as retas oblíquas são desconectadas na imagem, não havendo possibilidade de identificação do restante da imagem.




FIGURA 8 - Padrão desenvolvido por Dunn e Keizer (1989).

Schalkoff (1989) descreveu um sistema de reconstrução, com luz estruturada. Neste sistema utiliza-se de um projetor como “câmara ativa” que projeta um conjunto de raios no plano da imagem. O objetivo desta técnica é controlar a iluminação e simplificar o problema de determinação de correspondências. Os problemas deste método estão relacionados com a modelagem geométrica da câmara e do projetor.

Oosterlinck e Vuylsteke (1990) desenvolveram um padrão de iluminação para determinar a posição espacial do ponto a partir de uma forma binária. O padrão de iluminação utiliza-se de dois níveis de intensidade (preto e branco) que definem uma grade de pontos e marca cada ponto individualmente com um bit de codificação. Os pontos da grade a serem reconhecidos na cena são localizados a partir da intersecção das bordas horizontais e verticais, isto é, onde



quatro quadrados se encontram. Cada quadrado do tabuleiro é marcado por um quadrado menor na forma de um sinal claro ou escuro. A escolha dos códigos de bits para os pontos da grade é baseada em duas seqüências binárias. O tipo de padrão utilizado por Oosterlinck e Vuylsteke (1990) pode ser visto nas Figuras 9 e 10.




FIGURA 9 - Detalhe do padrão binário projetado.  
(Fonte: OOSTERLINCK e VUYLSTEKE, 1990).




FIGURA 10 - O padrão de iluminação composto de quatro primitivas.  
(Fonte: OOSTERLINCK e VUYLSTEKE, 1990).

Maas (1992) usou luz estruturada para a medição de superfícies de objetos que não apresentam textura na superfície. Neste método, trabalhou-se com dois tipos de objetos: um painel de carbono e um carro. Os padrões de luz estruturada são projetados sobre o objeto por um projetor de slides e a imagem é capturada por duas ou mais câmaras. O estabelecimento de correspondências é realizado usando informações de linhas epipolares. A quantidade de câmaras a serem usadas depende da superfície, dos valores aproximados das coordenadas e do número de pontos projetados.

Plassman (1995) apud Scalco (2000) utilizou luz estruturada para a medida de ulcerações cutâneas. O instrumento desenvolvido projeta uma seqüência de faixas paralelas de luz sobre a superfície da ulceração. Estes padrões são capturados pela câmara e processados em um sistema computacional conectado a ela. O mapa de profundidade é obtido por triangulação.

Singh et al (1997) apud Scalco (2000) utilizaram o princípio de luz estruturada na medição de coordenadas 3D da superfície sem textura. Estas coordenadas são determinadas pela combinação de um método de limiarização convencional e correlação por mínimos quadrados.

Scalco (2000) utilizou o sistema 3DScan com o princípio de luz estruturada. Este sistema foi desenvolvido no Departamento de Cartografia da Unesp de Presidente Prudente (TOMMASELLI, 1997) e baseia-se na intersecção das retas projetantes, calculadas a partir de pontos homólogos na imagem e no projetor, após a correspondência entre eles. A partir desta intersecção, as coordenadas 3D dos pontos na superfície são determinadas. As coordenadas do centro do alvo são calculadas pela média geométrica entre os centros de massa. O alvo deve ser maior que uma determinada área informada anteriormente para não ser considerado um ruído. A imagem é varrida *pixel a pixel* e, ao ser encontrado um *pixel* colorido, este é rotulado e é obtido um centro inicial do alvo. A partir dos experimentos realizados por Scalco (2000) com os algoritmos de correlação, alguns inconvenientes puderam ser percebidos como:

- Necessidade de definir diferentes imagens de referência para cada tipo de alvo;

- Necessidade de redefinir as imagens de referência para cada cena a ser reconstruída porque os alvos se modificam consideravelmente, limitando a automação do sistema;

As vantagens deste processo são:

- Confiabilidade equivalente a sistemas estéreo-fotogramétricos convencionais;
- Componentes de baixo custo, disponíveis no mercado da informática;
- Redução da complexidade do sistema devido à introdução do projetor de padrões, que possui geometria conhecida e que pode ser tratado como uma segunda câmara.

## **CAPÍTULO IV**

### **4. RECONHECIMENTO DE PADRÕES**

O reconhecimento de padrões consiste em dotar uma máquina com a capacidade de aproximar, em um determinado sentido, a capacidade similar dos seres humanos. Por exemplo, em um sistema para a leitura automática de imagens de documentos datilografados, os padrões de interesse são caracteres alfanuméricos, enquanto a meta é atingir uma dada precisão de reconhecimento de caracteres que sejam a mais próxima possível à excelente capacidade exibida por seres humanos na realização de tais tarefas (GONZALES e WOODS, 2000).

Segundo JAIN et al (2000), o sistema de reconhecimento de padrões, na maioria das vezes, engloba cinco etapas: aquisição de dados; pré-processamento; extração de características; seleção de características (análise dos dados) e classificação (decisão).

Algumas aplicações do reconhecimento de padrões estão vinculadas à classificação de documentos (procurar textos em documentos); organização e recuperação de base de dados; e, biométrica (identificação de pessoas a partir do conhecimento de atributos físicos, tais como, face e impressão digital). Outras aplicações estão descritas na Tabela 3.

TABELA 3 – Exemplos de aplicações de reconhecimento de padrões.

(Fonte: JAIN et al, 2000)

<b>Domínio do problema</b>	<b>Aplicação</b>	<b>Padrão de entrada</b>	<b>Classes do padrão</b>
Bioinformática	Análise de seqüências	DNA/ Seqüência protéica	Conhecimento dos tipos de genes
Mineração de dados	Procura por padrões significativos	Pontos em espaços multidimensionais	Agrupamentos compactos e bem distribuídos
Classificação de documentos	Procura na Internet	Texto	Categorias semânticas (esporte, turismo, etc).
Indústria	Inspeção na placa de circuitos	Imagem de intensidade	Natureza do produto: defeituosa ou não
Recuperação de dados	Procura na Internet	Vídeo clipe	Gêneros de filmes (ação, suspense).
Reconhecimento biométrico	Identificação pessoal	Face, íris, impressão digital.	Usuários autorizados para uma área de acesso
Sensoriamento remoto	Prever o rendimento da colheita	Imagens multiespectrais	Categorias de uso da terra, padrão de crescimento das colheitas.

A etapa de reconhecimento de padrões é ainda um grande problema para pesquisas realizadas nas áreas de Fotogrametria e de Visão Computacional porque as propostas tendem a se concentrar em uma tarefa específica ou são difíceis de serem usadas. Além disto, segundo Gonzales e Woods (2000), como este procedimento é muito complexo, há a necessidade de formular algumas restrições e idealizações para reduzir a complexidade da tarefa a um nível tratável.

Segundo Jain et al (2000), as quatro melhores abordagens para o reconhecimento de padrão são: correspondência por padrão, classificação estatística, correlação estrutural ou sintática e redes neurais.

#### 4.1. Correspondência por padrão (*Template matching*)

Segundo Schenk (1999), o método de correspondência por padrão é um método baseado em área, que consiste em comparar a distribuição de níveis de cinza de uma matriz amostra (padrão) com matrizes candidatas pertencentes a uma matriz de busca, usando uma função de correlação adequada (Figura 11).




FIGURA 11 – Pesquisa bidimensional de imagens correlatas.

(Adaptado de ANDRADE, 1998).

Na Fotogrametria, não há métodos de correlação que possam ser empregados para todas as aplicações. Portanto, algumas considerações a respeito do ambiente são necessárias: localização aproximada dos alvos; iluminação; se os

alvos encontram-se parcialmente oclusos; tempo de resposta; precisão; acurácia; confiabilidade; deformação geométrica e radiométrica; e, rotação dos alvos.

Além disso, alguns aspectos devem ser discutidos neste método como (SCHENK, 1999):

- Dimensão do padrão: padrões com dimensões maiores garantem uma melhor correspondência, porém, aumentam o custo computacional;
- Localização e dimensão da janela de busca – o método de correspondência baseado em área garante boas aproximações, e, portanto, métodos de redução do espaço de busca devem ser usados.

#### *4.1.1. Funções básicas de correlação*

Segundo Schenk (1999), as técnicas de correlação possuem uma grande tradição na determinação de pontos conjugados na Fotogrametria. A idéia fundamental da técnica de correlação é medir a similaridade entre o padrão e a janela de busca, calculando o coeficiente de correlação. Este coeficiente de correlação é determinado para cada matriz candidata, pertencente à matriz de busca, e, dependendo da função escolhida, determina-se a matriz homóloga ao padrão, a partir do ponto de máximo ou mínimo.

As principais funções para a determinação de correspondência por correlação são: função correlação, função covariância cruzada, função erro, função erro modificada e função quociente.

#### 4.1.1.1. Função covariância cruzada

A melhor janela de correlação, nesta função, ocorre quando o coeficiente de correlação a ser determinado é máximo. A função covariância cruzada pode ser observada na Equação 20.

$$\rho = \frac{1}{r_x r_y} \sum_{i=0}^{r_y-1} \sum_{j=0}^{r_x-1} [g_r(i, j) - \bar{g}_r][g_b(i + a, j + b) - \bar{g}_b] \quad (20)$$

Onde:

$\rho$  - coeficiente de correlação;

$g_r, g_b$  - níveis de cinza da janela de referência (matriz amostra) e da matriz candidata, respectivamente;

$r_x, r_y$  - dimensões da janela de referência na coluna e na linha, respectivamente;

$i, j$  - índices dos *pixels* na janela de referência e na matriz candidata;

$a, b$  - valores para mudanças de posição em linha e coluna na janela de busca (matriz de busca).

$\bar{g}_r, \bar{g}_b$  - médias dos níveis de cinza da janela de referência e da matriz candidata.



#### 4.1.1.2. Função covariância cruzada modificada ou coeficiente de correlação

Esta função de correlação é resultado da normalização da função covariância cruzada (Seção 4.1.1.1) (Equação 21). O coeficiente de correlação, neste caso, varia de  $-1$  a  $1$ . O valor  $1$  para o coeficiente de correlação corresponde a medida de similaridade máxima, o valor  $0$  indica que não há correlação e o valor  $-1$  indica correlação inversa (KRAUS, 1993)

$$\rho = \frac{\sigma_{rb}}{\sigma_r \sigma_b} = \frac{\sum (g_r(i, j) - \bar{g}_r)(g_b(i + a, j + b) - \bar{g}_b)}{\sqrt{\sum (g_r(i, j) - \bar{g}_r)^2 \sum (g_b(i + a, j + b) - \bar{g}_b)^2}} \quad (21)$$

Onde:

$\sigma_{RB}$  – covariância entre a janela de referência e a matriz candidata;

$\sigma_R$  – desvio-padrão da janela de referência;

$\sigma_B$  – desvio-padrão da matriz candidata.

O problema desta função é quando o denominador for igual a zero, isto é, quando a janela de referência ou a matriz candidata forem homogêneas.

Para evitar estes casos, é importante fazer uma pré-análise da janela de referência (COSTA et al, 2003).

#### 4.1.1.3. Função correlação cruzada

Esta função de correlação consiste no produto entre os tons de cinza da janela de referência e a matriz candidata. O maior valor do coeficiente de correlação corresponde a melhor correspondência na matriz homóloga.

$$\rho = \frac{1}{r_x r_y} \sum_{i=0}^{r_y-1} \sum_{j=0}^{r_x-1} g_r(i, j) g_b(i + a, j + b) \quad (22)$$

#### 4.1.2. Correspondência por mínimos quadrados

Este método de correspondência tem como objetivo procurar o menor valor para o somatório dos quadrados das diferenças entre os níveis de brilho entre ambas as imagens, isto é, refinar a solução de tal modo que  $\sum e^2 = \text{mínimo}$  (ANDRADE, 1998 e ACKERMAN, 1984).

Gruen (1996) detalha o método de correlação por mínimos quadrados bidimensionalmente. Inicialmente, assume-se que a janela de referência e a janela de pesquisa são idênticas. Como as imagens são afetadas por ruído, insere-se uma função erro a uma das imagens (Equação 23).

$$f(x, y) - e(x, y) = g(x, y) \quad (23)$$

A Equação 23 pode ser considerada como uma equação que associa o vetor das observações  $f(x, y)$  com uma função  $g(x, y)$ , na qual a localização na janela de pesquisa em relação a janela de referência necessita ser estimada. Esta localização é descrita por parâmetros de deslocamento  $(\Delta x, \Delta y)$  relacionados à posição inicial de  $g(x, y)$ .

Para determinação de uma melhor correspondência, parâmetros relacionados à geometria e à radiometria são inseridos. Primeiramente, a transformação geométrica é modelada pelo seguinte polinômio:

$$\begin{aligned} x &= t_y^T \bar{A} t_x \\ y &= t_y^T \bar{B} t_x \end{aligned} \quad (24)$$

Onde:

$$\begin{aligned} t_x^T &= \{1 \quad x_0 \quad x_0^2 \quad \dots \quad x_0^{m-1}\} \\ t_y^T &= \{1 \quad y_0 \quad y_0^2 \quad \dots \quad y_0^{m-1}\} \end{aligned} \quad (25)$$

$$\bar{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & & & \\ \vdots & & & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mm} \end{bmatrix}, \bar{B} = \begin{bmatrix} b_{11} & b_{12} & \dots & b_{1m} \\ b_{21} & & & \\ \vdots & & & \\ b_{m1} & b_{m2} & \dots & b_{mm} \end{bmatrix}$$

$x_0, y_0$  - posições da malha regular dos pontos de  $g^0(x, y)$ ;

$g^0(x, y)$  - aproximação inicial da posição de  $g(x, y)$ .

Sendo a Equação 23 não linear, esta pode ser linearizada da forma expressa na Equação 26.

$$f(x, y) - e(x, y) = g^0(x, y) + \frac{\partial g^0(x, y)}{\partial x} dx + \frac{\partial g^0(x, y)}{\partial y} dy \quad (26)$$

$$dx = \frac{\partial x}{\partial p_i} dp_i \quad dy = \frac{\partial y}{\partial p_i} dp_i$$

Onde:

$p_i$  - parâmetros da transformação que serão obtidos posteriormente;

A partir de uma transformação afim com as matrizes  $\bar{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & 0 \end{bmatrix}$  e

$\bar{B} = \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & 0 \end{bmatrix}$ , tem-se:

$$x = a_{11} + a_{12}x_0 + a_{21}y_0 \quad (27)$$

$$y = b_{11} + b_{12}x_0 + b_{21}y_0$$

Onde:

$a_{11}, b_{11}$  - equivale aos parâmetros de translação  $\Delta x, \Delta y$ .

Realizando uma diferenciação da Equação 27, tem-se:

$$dx = da_{11} + da_{12}x_0 + da_{21}y_0 \quad (28)$$

$$dy = db_{11} + db_{12}x_0 + db_{21}y_0$$

Simplificando a Equação 28 e acrescentando os parâmetros radiométricos  $r_s$  (deslocamento - brilho) e  $r_e$  (escala - contraste), a Equação 26 equivale a:

$$f(x, y) - e(x, y) = g^o(x, y) + g_x da_{11} + g_{xx_0} da_{12} + g_{xy_0} da_{21} + g_y db_{11} + g_{yx_0} db_{12} + g_{yy_0} db_{21} + r_s + g^0(x, y) r_e \quad (29)$$

Onde:

$$g_x = \frac{\partial^0_g(x, y)}{\partial x} \quad g_y = \frac{\partial^0_g(x, y)}{\partial y}$$

Combinando os parâmetros da Equação 29 no vetor X, tem-se:

$$X^T = \{da_{11}, da_{12}, da_{21}, db_{11}, db_{12}, db_{21}, r_s, r_e\}$$

Para estimar estes parâmetros pode ser usado o método paramétrico (GEMAEL, 1994) que é adequado para modelos do tipo explícito.

$${}_n La_1 = F({}_u Xa_1) \quad (30)$$

Onde:

$La$  – vetor dos valores observados ajustados;

$Xa$  – vetor dos parâmetros ajustados;

$n$  – número de observações;

$u$  – número de incógnitas.

Sabendo que  $La = Lb + V$  e  $Xa = Xo + X$ , a equação acima linearizada pode ser descrita por:

$$Lb + V = F(Xo + X) = F(Xo) + \left. \frac{\partial F}{\partial Xa} \right|_{Xa=Xo} X \quad (31)$$

Sendo  $Lo = F(Xo)$  e  $A = \left. \frac{\partial F}{\partial Xa} \right|_{Xa=Xo}$ , a Equação 31 pode ser reescrita

como:

$$Lb + V = Lo + AX \quad (32)$$

Considerando  $L = Lo - Lb$ , a equação torna-se:

$${}_nV_1 = {}_nA_{uu} X_1 + {}_nL_1 \quad (33)$$

Onde:

$V$  – vetor dos resíduos;

$A$  – matriz das derivadas parciais;

$X$  – vetor das correções aos parâmetros;

$Lo$  – vetor dos valores aproximados;

$Lb$  – vetor dos valores observados.

O vetor dos parâmetros ajustados é determinado a partir de:

$$Xa = Xo + X \quad (34)$$

Onde:

$$X = -(A^T P A)^{-1} A^T P L;$$

$X_0$  - vetor dos parâmetros aproximados;

$P$  – matriz peso.

Após a estimação dos parâmetros geométricos e radiométricos, uma transformação afim direta é aplicada para determinação das coordenadas e a janela de pesquisa é reamostrada usando o método de interpolação bilinear para o cálculo dos novos níveis de cinza. A iteração deste processo ocorre até que os valores absolutos dos parâmetros geométricos sejam menores que o critério de convergência adotado (Equação 35).

$$\begin{aligned} |da_{11}| < c_1 & \quad |da_{12}| < c_3 & \quad |da_{21}| < c_5 \\ |db_{11}| < c_2 & \quad |db_{12}| < c_4 & \quad |db_{21}| < c_6 \end{aligned} \quad (35)$$

Onde:

$c_i, 1 \leq i \leq 6$  - *critérios de convergência*.

Os critérios de convergência escolhidos dependem da imagem utilizada. Para isto, antes de realizar todo o processo automático, necessita realizar um treinamento.

O conceito básico da interpolação bilinear é realizar a interpolação linear nas direções das linhas e das colunas. O modelo matemático para a interpolação bilinear (Equação 36) pode ser estabelecido com base na Figura 12.




FIGURA 12 - Representação do *pixel* reamostrado.

$$NC_{IR} = (1 - dx) * (1 - dy) * NC_I(i, j) + dx * (1 - dy) * NC_I(i + 1, j) + dy * (1 - dx) * NC_I(i, j + 1) + dx * dy * NC_I(i + 1, j + 1) \quad (36)$$

Onde:

$NC_{IR}$  - nível de cinza da imagem reamostrada;

$NC_I$  - nível de cinza da janela de pesquisa;

$i, j$  - coordenadas da janela de pesquisa.

A estimação do modelo matemático deve acomodar os parâmetros suficientes para realizar uma boa modelagem das distorções radiométricas e geométricas para não ocorrer o problema de superparametrização. Isto quer dizer que o modelo a ser escolhido deve conter apenas os parâmetros que conseguirão ser determinados porque, caso contrário, estes dados trarão um efeito negativo ao resultado, deteriorando a qualidade do mesmo. Testes podem ser realizados para determinar aqueles parâmetros que são não-determináveis. Isto pode ser realizado trabalhando com variáveis estocásticas, associando pesos que devem estar



relacionados ao tamanho da distorção a ser esperada. Alguns alvos binários no quais certos parâmetros não podem ser determinados encontram-se na Figura 13.



FIGURA 13 – Padrões que reduzem a quantidade de parâmetros a serem determinados pelo modelo matemático mencionado nesta seção. (a) escala em y; (b) rotação; (c) duas escalas; (d) todos na direção y; (e) todos na direção y e escala em x; (f) todos (Fonte: GRUEN, 1996).

O modelo matemático pode ser simplificado, considerando apenas os parâmetros geométricos supondo-se que uma normalização geométrica tenha sido realizada previamente.

## 4.2. Correspondência por assinatura

Segundo Gonzales e Woods (2000), a definição de assinatura é uma representação funcional unidimensional de uma fronteira. Há várias maneiras de se determinar a assinatura de um alvo. Uma das maneiras mais fáceis de obtê-la é a partir do gráfico da distância do limite ao centróide em função do ângulo. Esta assinatura é invariante à translação, mas depende da rotação e mudança de escala. Exemplos deste tipo de assinatura podem ser observados na Figura 14.




FIGURA 14 – Fronteiras e suas respectivas assinaturas.

Segundo Sonka et al (1998), a assinatura pode ser obtida como uma seqüência da distância dos contornos normais. Esta distância é calculada para cada elemento da fronteira como uma função da distância, isto é, para cada ponto pertencente à fronteira são traçadas a sua tangente e a sua normal até que a normal intercepte o outro lado da fronteira. Como as assinaturas são sensíveis a ruídos, uma suavização na fronteira é necessária para redução destes. A forma de obter esta assinatura pode ser vista na Figura 15.




FIGURA 15 – Assinatura: (a) Princípio da construção (b) Assinaturas para um círculo e um triângulo. (Fonte: Adaptado de SONKA et al, 1998).

Como o método da assinatura depende da rotação, uma normalização é realizada através do estabelecimento do ponto inicial para a geração da assinatura. Uma das maneiras de determinar este ponto é escolher o ponto com maior distância ao centróide, caso o mesmo seja único e independente de rotação dos objetos de interesse.

Um outro problema da assinatura está relacionado com a mudança de amplitude advinda dos diferentes tamanhos dos padrões. Para resolver isto, uma mudança simples de escala de todas as funções de maneira que as mesmas variem dentro do mesmo domínio é necessária. Este método é bem simples, porém, tem a desvantagem da função depender apenas de dois valores: o máximo e o mínimo. Uma melhor abordagem consiste na divisão da amostra pela variância, desde que a mesma seja diferente de zero. A idéia, neste caso, é remover a dependência, preservando a forma fundamental da função.

Para verificar a similaridade entre duas assinaturas, vários critérios podem ser usados. Na Seção 4.2.1, observa-se alguns critérios para a determinação da discrepância entre as assinaturas.

#### *4.2.1. Determinação da discrepância entre as assinaturas*

Segundo Mustafa et al (1999), esta discrepância pode ser determinada a partir do cálculo de quatro erros métricos entre as assinaturas armazenada e gerada na cena. Estes erros são:

- Erro de distância: mede a distância entre duas distribuições espaciais das assinaturas. Valores próximos a zero indicam que as distribuições possuem o mesmo valor médio e são distribuídas ao redor dos mesmos pontos de frequência. Os valores próximos a unidade refere-se a distribuições ao redor de diferentes frequências. Este erro é calculado por:

$$\varepsilon(S_1, S_2) = \frac{1}{c_n} |\mu_1 - \mu_2| \quad (37)$$

Onde:

$S_1, S_2$  - assinaturas a serem comparadas;

$c_n$  – constante de normalização;

$\mu_1, \mu_2$  - médias das assinaturas.

Um problema na determinação deste erro está relacionado à definição da constante de normalização já que o processo é automático e esta constante de normalização depende dos dados de entrada usados.

- Erro na forma: mede a diferença de variância entre as assinaturas. Valores próximos a zero indicam que as formas de ambas as assinaturas são similares. Este erro é dado por:

$$\varepsilon(S_1, S_2) = \begin{cases} 0 & \sigma_1 = \sigma_2 = 0 \\ \frac{|\sigma_1 - \sigma_2|}{\sigma_1 + \sigma_2} & \end{cases} \quad (38)$$

Onde:

$\sigma_1, \sigma_2$  - desvios-padrão da distribuição;

- Erro de dispersão: mede a diferença de dispersão da distribuição entre duas assinaturas em relação à média. Valores próximos a zero indicam que as assinaturas são similares. Este erro é dado por:

$$\varepsilon(S_1, S_2) = \frac{|\lambda(S_1, \bar{\sigma}_1) - \lambda(S_2, \bar{\sigma}_2)|}{\lambda(S_1, \bar{\sigma}_1) + \lambda(S_2, \bar{\sigma}_2)} \quad (39)$$

$$\lambda(S, \bar{\sigma}) = \sum_{k=\mu-\bar{\sigma}}^{k=\mu+\bar{\sigma}} S_k \quad \text{e} \quad \bar{\sigma} = \frac{1}{2}(\sigma_1 + \sigma_2)$$

- Erro de correlação: mede a correlação entre as duas assinaturas. Valores próximos a zero indicam forte correlação e conseqüentemente grande similaridade. A fórmula para determinar este erro é:

$$\varepsilon(S_1, S_2) = 1 - \left| \frac{\sum (S_1 - \mu_1)(S_2 - \mu_2)}{\sqrt{\sum (S_1 - \mu_1)^2} \sqrt{\sum (S_2 - \mu_2)^2}} \right| \quad (40)$$

O problema encontrado para determinação deste erro de correlação está relacionado às duas assinaturas terem que possuir a mesma quantidade de *pixels* no alvo. Por isso, há a necessidade de realizar uma amostragem dos dados.

### 4.3. Outras técnicas para o reconhecimento de padrões

Mayr e Poth (1995) utilizaram o processo de correlação binária para a identificação de marcas fiduciais. Cada marca fiducial é localizada independentemente. A boa qualidade da solução no nível anterior da pirâmide de imagens reduz a janela de procura, aumentando a velocidade do processo. Esta técnica denominada de pirâmide de imagens consiste de um conjunto de imagens reamostradas da imagem original, cada uma com um grau de resolução menor. A acurácia final obtida está em torno de 0.1 *pixel*.

Picard (1997) apud Jain (2000) identificou uma aplicação moderna de reconhecimento de padrão, chamada de computação afetiva que dará ao computador a habilidade de reconhecer e de expressar emoções, responder inteligentemente a emoção humana e empregar mecanismos de emoção nas decisões racionais.

Drewniok e Rohr (1997) desenvolveram uma abordagem automática para orientação exterior de imagens aéreas baseada no ajustamento analítico de modelos à imagem. Esta técnica é denominada ajustamento por modelo e possui como objetivo a detecção e localização das marcas artificiais (pontos pré-sinalizados) ou naturais (pontos de controle). A utilização destes modelos é recomendada quando se deseja alta acurácia no momento da localização e quando se tem uma alta variabilidade estrutural.

Mustafa et al (1999) descrevem um sistema para identificação do objeto. Dado um conjunto de objetos 3D e uma cena contendo um ou mais destes objetos, o sistema identifica quais os objetos que aparecem na cena através do

método de assinatura. Neste trabalho, dois tipos de assinaturas são utilizados: curvatura e espectral. Para testar a discrepância entre duas assinaturas, quatro erros métricos são usados: erro de distância, erro na forma, erro de dispersão e erro de correlação. Este sistema testou 95 objetos e conseguiu bons resultados em aproximadamente 77 objetos.

Howard e Padgett (1999) implementaram um programa para o reconhecimento de padrões em imagens de satélite em tempo real usando redes neurais. Primeiramente, realizou-se a segmentação da imagem para separar os diferentes tipos de alvos existentes nas imagens a partir de um agrupamento (*clustering*). Os alvos obtidos deste agrupamento foram treinados a partir de um classificador de redes neurais para validar ou não se o alvo extraído contém um dos alvos agrupados anteriormente. Valores acima de um limiar escolhido dependendo da imagem que se está trabalhando são considerados como objeto e os menores, como fundo. Testes realizados mostraram que o algoritmo conseguiu detectar 99% dos alvos quando usou imagens hiper-espectrais. Os problemas encontrados nas redes neurais para o reconhecimento de padrões estão relacionados à demora do processo referente ao treinamento e aos valores de pesos a serem estipulados no início dos processos intermediários. Além disto, os processos intermediários não são transparentes e nem de entendimento fácil, atrapalhando o desenvolvimento.

Ting e Leung (1999) propuseram uma técnica baseada na descrição de estruturas lineares usando um conjunto de caracteres. Linhas, textos e espaços são convertidos em representações lineares. O documento é lido da esquerda para direita e de cima para baixo. A cada objeto encontrado, especifica-se o seu tipo, isto é, linha vertical, linha horizontal, caixa de texto ou espaço em branco. Conhecendo o seu tipo, um conjunto de caracteres é criado com todos os objetos do documento.

Para saber se este documento é idêntico a outro, compara-se o conjunto de caracteres de ambos os documentos. O uso desta técnica permite uma medida rápida e robusta de similaridade entre dois documentos. Além disto, este processo de descrição de conjunto de caracteres permite uma tolerância significativa em relação às inconsistências da segmentação. Testes realizados mostraram boas soluções. Porém, esta técnica depende das primitivas usadas para determinar o conjunto de caracteres. Quanto maior o número de primitivas, melhor o resultado a ser encontrado, porém, maior o custo computacional. Além disso, outros problemas dificultam este reconhecimento de padrões: distorções do documento e símbolos incompletos.

Hattori et al (2000) realizaram medidas simuladas de uma geladeira doméstica com um desenho especial para os alvos codificados (Figura 16). Pela dificuldade em encontrar os alvos devido às diferenças de profundidade, estes necessitam ser selecionado no pré-processamento. Os alvos devem ser bem distribuídos para facilitar na sua medição.

O padrão do desenho é feito de um material circular refletivo que é fixado no objeto. O tamanho do alvo é ajustado para que um pequeno círculo na imagem tenha aproximadamente 3 *pixels*. A codificação é realizada a partir dos bits associados ao círculo.

Primeiramente, um número pequeno de alvos codificados foi identificado para obter os parâmetros de orientação, enquanto, os alvos medidos foram identificados pela intersecção de múltiplos raios.

Este processo conseguiu reconhecer 97% dos alvos das imagens por uma simples binarização de imagens.






FIGURA 16 – Alvo codificado (Fonte: HATTORI et al, 2000).

## CAPÍTULO V

### 5. MATERIAIS E MÉTODOS

#### 5.1. Materiais

Nesta seção estão listados os equipamentos e programas computacionais que foram usados para a realização deste trabalho de pesquisa:

- Uma câmara digital KODAK DX 3500;
- Um computador AMD Athlon XP 2200+, 80 GB de disco rígido e 256 MB de memória RAM;
- Um projetor de padrões composto por:
  - i. Sistema de lentes;
  - ii. Suporte para fixação dos fotolitos a serem projetados;
  - iii. Sistema de iluminação;
  - iv. Condensador interno e *flash*;
  - v. Suporte para acoplar a câmara digital.
- Compilador Borland C/C++ Builder 5.0;
- Software Microstation Bentley.
- Microsoft Office 2000 Standard;
- Software Paint Shop Pro 4.0.
- Software Surfer 7.0 Demo.

## 5.2. Métodos

Para compreensão dos processos envolvidos para a classificação e a localização precisa dos alvos, um fluxograma é apresentado na Figura 17.

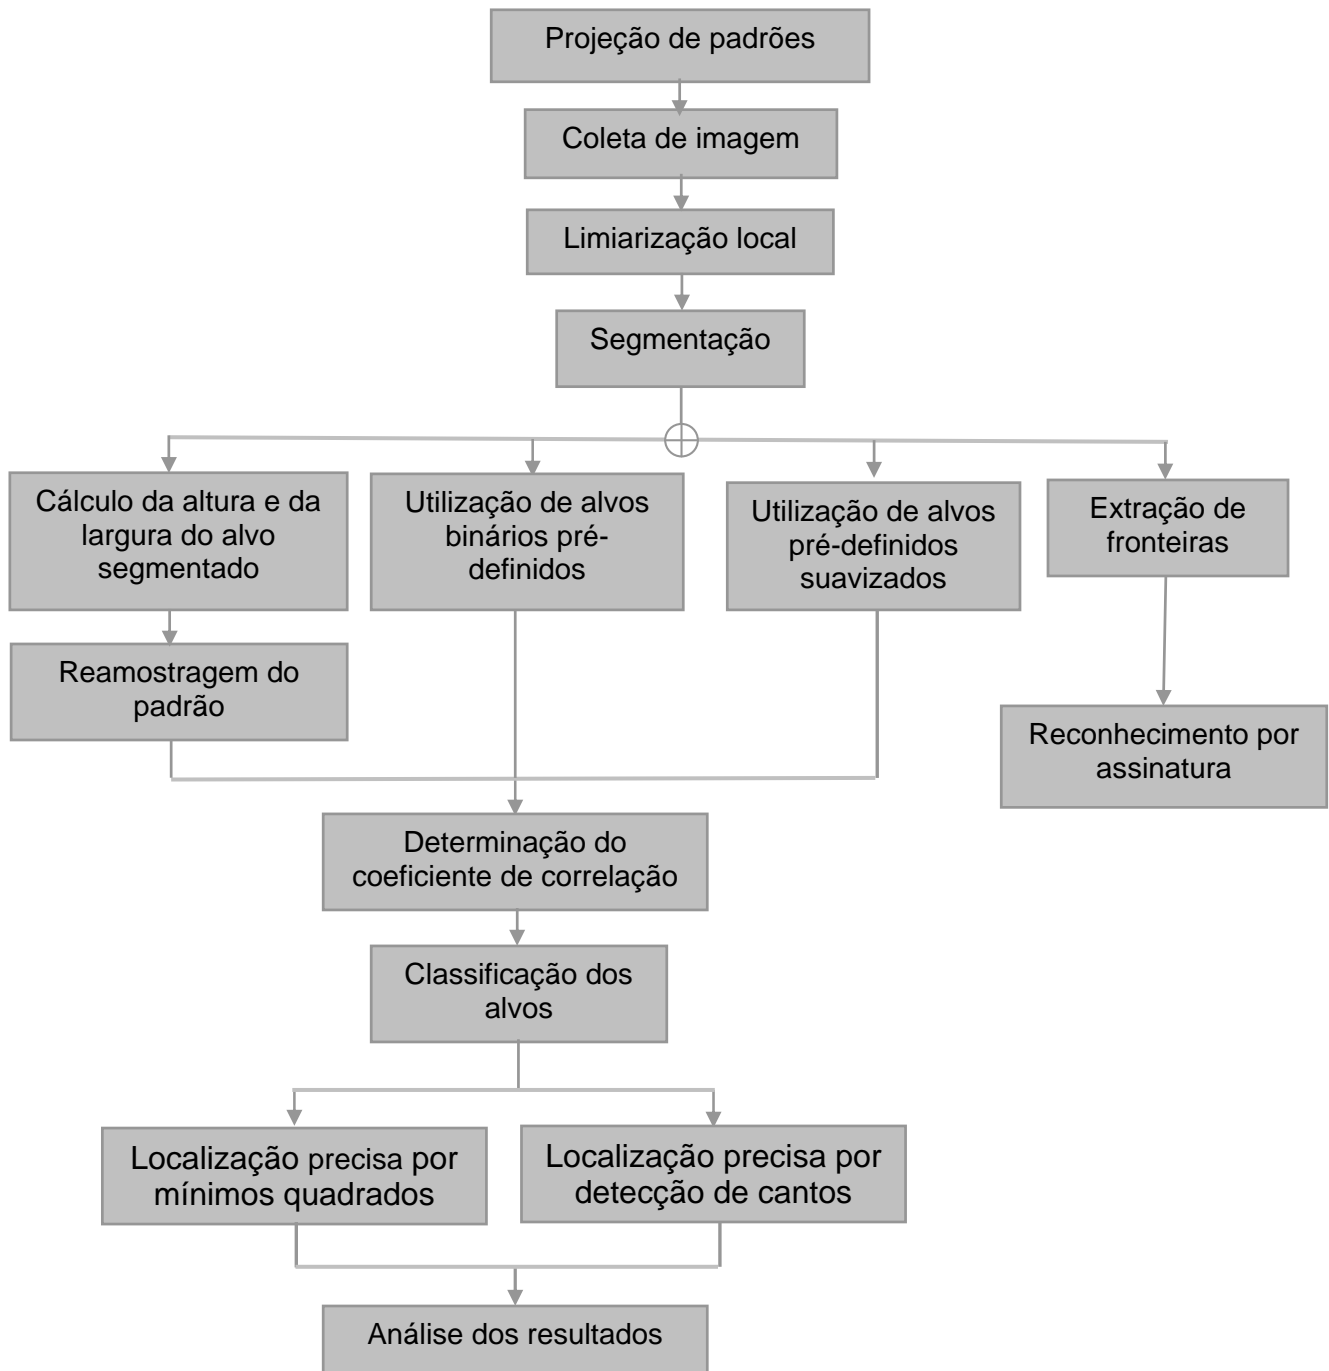


FIGURA 17 – Seqüência das operações e processamentos realizados.

### 5.2.1. Geração de padrões

No método de reconhecimento de padrões a ser usado, cada padrão necessita ser classificado unicamente, pois a cada um estão associados os parâmetros de seu vetor diretor para determinação das coordenadas 3D.

Estudos anteriores utilizaram padrões projetados com luz branca sob formas circulares e padrões baseados em uma combinação de formas e cores. Apesar das formas circulares serem de fácil identificação automática, estas se mostraram inadequadas quando alguns padrões eram oclusos, isto pois inviabilizava a análise de vizinhança.

A utilização de padrões com diferentes formas e cores possibilita a identificação automática de alguns casos de oclusão, porém, as cores dos padrões projetados podem coincidir com a superfície dos objetos, acarretando em erros na segmentação de alvos.

Observando estes problemas, chegou-se a várias possibilidades de abordagens, sendo a mais adequada, a utilização de padrões de luz branca com formas específicas. Entretanto, haveria a necessidade de alguma técnica para que estes padrões pudessem ser reconhecidos univocamente em relação aos demais. Uma solução seria a utilização de padrões com formas diferentes umas das outras. Esta solução seria impraticável, pois haveria a necessidade de muitas formas para compor todos os padrões e de um banco de dados relativamente grande para armazenar cada uma das características dos padrões pré-definidos. Isto traria um aumento do custo computacional para a identificação de cada padrão e aumentaria a possibilidade de redundância no reconhecimento.

A solução mais viável foi utilizar um conjunto pequeno de formas e conciliá-las com uma análise de vizinhança. Além disto, procurou-se gerar padrões de forma a privilegiar a existências de quinas, que poderiam ser usados como pontos para localização precisa. Os padrões escolhidos são mostrados na Figura 18.



FIGURA 18 - Padrões primitivos.

Com estas cinco formas é possível classificar cada padrão dentro, naturalmente, de cinco classes, que serão rotuladas pelas letras: A, B, C, D e E, cujas relações entre forma e rótulo são mostradas na Figura 18. Como a forma do padrão representado pela letra A é a que possui maior facilidade de ser detectada, dentre as demais formas, usando o método de correlação de imagens, este padrão foi assumido como pivô de uma estrutura bidimensional de vizinhança oito (Figura 19). Além disto, a geração dos padrões seguiu algumas restrições:

- Padrões do tipo A não possuem outro A como vizinho;
- Assumindo-se que uma máscara de padrões é formada por nove elementos em uma matriz 3x3 com um padrão A como pivô, não há outra máscara de padrões semelhante dentro de um raio de quatro pivôs A, isto é, dentro deste raio, somente a metade dos padrões é idêntica.




FIGURA 19 – Vizinhança dos padrões.

Apenas com o intuito de facilitar na leitura, decidiu-se nomear os protótipos primitivos por padrões e os protótipos projetados como alvos.

#### 5.2.2. Coleta de dados

A coleta de dados é realizada a partir de um sistema baseado no princípio de luz estruturada. Este sistema é composto por um sistema projetor de padrões de luz estruturada e um sensor (uma câmara digital de pequeno formato e de foco fixo) (Figura 20).




FIGURA 20 - Sistema sensor e projetor.

A câmara usada para a construção deste protótipo com o sistema de luz estruturada foi a KODAK DX 3500 que possui uma distância focal nominal de 38 mm, resolução máxima de 1800 x 1200 *pixels* e tamanho do *pixel* de 19,44  $\mu\text{m}$  considerando um tamanho teórico do sensor de 35 mm. As vantagens desta câmara são: foco fixo e disparo de um único *flash* por imagem.

Esta câmara foi calibrada por meio de um processo de calibração por feixe de raios (*bundle method*) usando o programa CC (GALO, 1993). Neste processo, apenas os quatro parâmetros mais significativos foram considerados: distância focal, ponto principal  $(x_0, y_0)$  e o primeiro parâmetro de distorção radial simétrica  $K_1$ . A quantidade de pontos de apoio, de fotocoordenadas e de imagens usada para a calibração da câmara foi de 28, 80 e 6, respectivamente. Os resultantes são mostrados na Tabela 4. Maiores informações a respeito da calibração podem ser encontradas em Reiss e Tommaselli (2004).

TABELA 4 - Parâmetros de orientação interior calibrados.  
(REISS e TOMMASELLI, 2004).

Parâmetros	Valores estimados	Desvios-padrão estimados
$f$ (mm)	38,329	0,012
$x_0$ (mm)	-0,297	0,008
$y_0$ (mm)	-0,226	0,013
$K_1$ (mm)	-0,000102184	$0,3984 \times 10^{-6}$

O projetor de padrões é composto de fotocélula, condensador interno, placa com os padrões, bateria, lentes e espelho (Figura 20). O fotolito foi impresso usando um processo fotográfico e encontra-se entre duas placas de vidro planas, usadas para absorver parte do calor gerado pela lâmpada. O controlador do *flash* assegura a sincronização entre o instante de aquisição da imagem pela câmara e a iluminação da cena pelo projetor. Este tipo de iluminação instantânea evita o aquecimento do projetor e a deformação do padrão reproduzido no material fotográfico. A calibração do projetor foi realizada por Reiss e Tommaselli (2004).

### 5.2.3. Limiarização local

Devido à lei de iluminância, a luz que atinge os cantos da imagem é atenuada por um fator de  $\cos^4 \theta$ , onde  $\theta$  é o ângulo entre o eixo óptico da câmara e o ponto em análise. Com isto a área central da imagem é mais iluminada que a periferia, gerando um efeito semelhante ao de vinhete, embora devido a causas



diferentes. Para reduzir este efeito, realizou-se uma etapa prévia de limiarização local, para separar o fundo do sinal gerado pelos alvos projetados.

O método usado foi o de limiarização local (Seção 2.7.3) porque se verificou experimentalmente a necessidade de definir diferentes limiares para cada região da imagem.

Inicialmente, foi considerada a hipótese de definir um valor de limiar para cada *pixel* da imagem (calculado a partir de uma pequena região em torno do *pixel*). Porém, devido ao grande volume de processamento que isto implicaria, uma nova estratégia foi desenvolvida e, resolveu-se implementar uma variante da limiarização pelos métodos de Otsu e de Pun. Neste caso, o limiar é calculado a partir de uma subimagem  $3w \times 3w$  e aplicado em uma janela  $w \times w$  (Figura 21). Maiores informações podem ser encontradas em ARTERO (1999). Isto permite uma transição suave de uma janela para outra, evitando o efeito de “ladrilho” na imagem limiarizada. *Pixels* com níveis de cinza inferiores ao limiar recebem zero enquanto os outros *pixels* permanecem com o nível de cinza original.

O processo desenvolvido é uma variante do método original, porque a imagem não é binarizada.




FIGURA 21 – Configuração da janela do limiar local.

#### 5.2.4. Segmentação

A segmentação dos alvos na imagem é feita usando o método de crescimento de regiões. Esta técnica consiste no agrupamento e na rotulação de todos os *pixels* de cada padrão. Isto é feito percorrendo toda a imagem até encontrar um *pixel* que possua um limiar maior que um limiar global determinado. Este *pixel* é denominado de *pixel* semente e é rotulado. A partir deste *pixel* semente, com coordenadas  $(i, j)$ , observam-se os *pixels* vizinhos: frente  $(i, j+1)$ , abaixo  $(i+1, j)$  e atrás  $(i, j-1)$ . Caso o nível de cinza de um destes *pixels* seja maior que o limiar global determinado, ele é agrupado ao *pixel* semente e rotulado. A segmentação do padrão finaliza quando os níveis de cinza dos *pixels* vizinhos forem menor que o limiar. Finalizada a segmentação do alvo, reinicia-se a varredura a partir do *pixel* semente do padrão segmentado anteriormente. Alvos pertencentes ao fundo recebem rótulo 1, zero indica que o *pixel* não foi rotulado e os padrões segmentados recebem rótulos de 2 até o número de alvos segmentados. Este procedimento é realizado até que todos os *pixels* da imagem tenham sido rotulados. As informações geradas neste procedimento são: centro de massa de cada alvo segmentado; número do rótulo e coordenadas de todos os *pixels* pertencentes ao alvo; e, os valores máximos e mínimos para cada padrão para a determinação da altura e da largura do alvo para posterior reamostragem. O centro de massa é determinado a partir de uma média ponderada das discrepâncias entre os níveis de cinza dos *pixels* segmentados e o limiar global determinado. Um fluxograma da etapa de segmentação de padrões pode ser observado na Figura 22.

Esta etapa de segmentação de padrões faz-se necessária para diminuir o número de máscaras a serem comparadas nos métodos de detecção de alvos por correspondência por padrão e assinatura. Isto torna menor o custo computacional porque este procedimento evita a busca de vários padrões por toda a imagem, procedimento que é pouco confiável, devido às várias respostas diferentes para o mesmo tipo de alvo.

#### *5.2.5 Classificação*

A etapa de classificação de padrões é fundamental porque é nesta etapa que os alvos são identificados e são definidos os valores aproximados para a localização precisa. Esta classificação visa atribuir a cada alvo segmentado, baseado nas suas características de forma, a qual classe de padrões ele tem maior probabilidade de pertencer, dentro das cinco classes pré-definidas (Figura 18).

Para a etapa de classificação, dois métodos foram implementados e comparados neste trabalho: correspondência por área usando as funções de correlação e o método de assinatura.

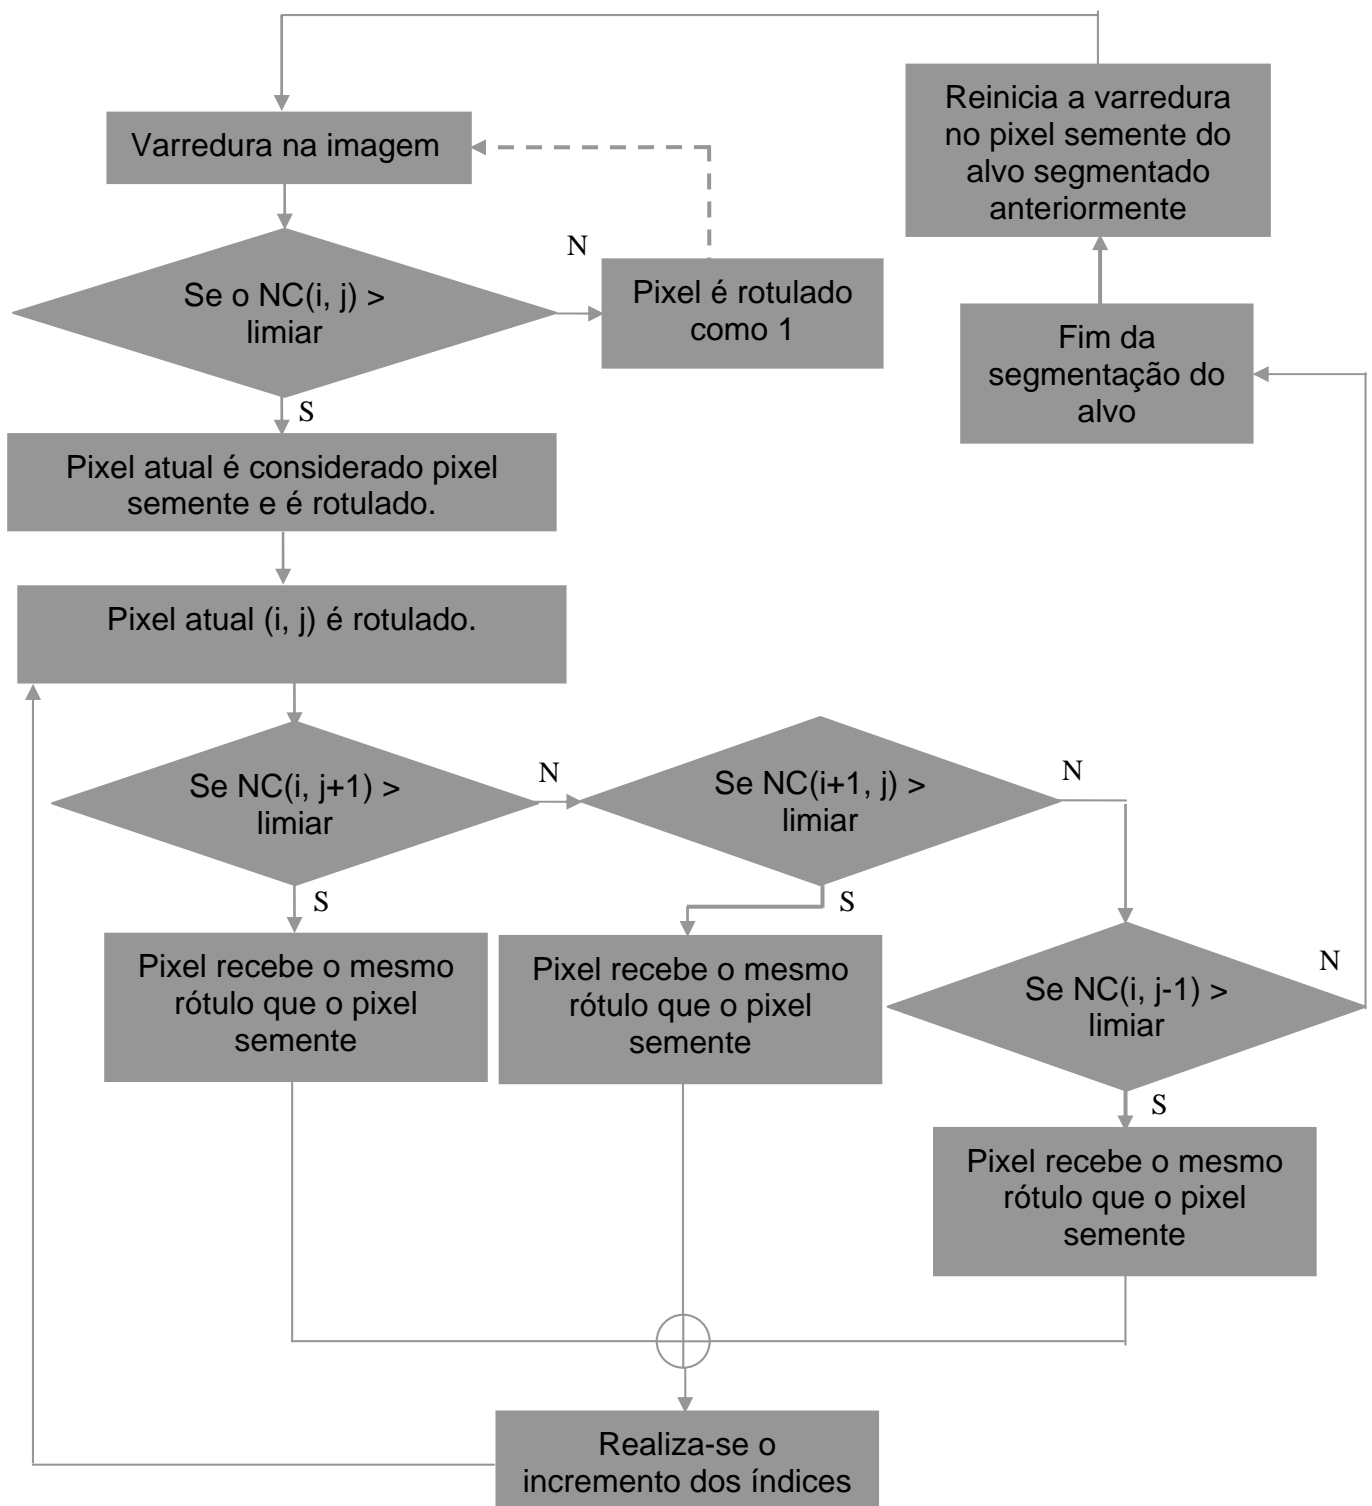


FIGURA 22 – Fluxograma do algoritmo de segmentação de padrões.

### 5.2.5.1 Correlação

Nesta etapa de classificação, três metodologias foram avaliadas: comparação dos alvos segmentados com os padrões pré-definidos e com as suas instâncias (cópia de um objeto com alterações em escala ou rotação) armazenadas, comparação dos alvos segmentados com os padrões pré-definidos suavizados e com as suas instâncias armazenadas suavizadas, comparação dos alvos segmentados com os padrões pré-definidos reamostrados.

#### - 1ª Metodologia: Comparação dos alvos segmentados com os padrões pré-definidos e as suas instâncias armazenadas (imagens binárias).

Neste caso, 45 padrões são armazenados para posterior comparação (Tabela 5). Estes padrões variam em relação à escala. Esta escala foi escolhida a partir de visualizações realizadas na imagem original.

TABELA 5 - Padrões pré-definidos e as suas instâncias armazenadas.

Padrão Tamanho (pixels)	A	B	C	D	E
11 x 11					
13 x 13					
15 x 15					
17 x 17					
19 x 19					
13 x 15					
15 x 13					
15 x 17					
17 x 15					

**- 2ª Metodologia: Comparação dos alvos segmentados com os padrões pré-definidos e as suas instâncias armazenadas suavizadas.**

Neste caso, os mesmos 45 padrões são armazenados para posterior comparação. Porém estes padrões sofreram uma suavização pela média antes da comparação com os alvos segmentados.

Os inconvenientes das duas metodologias anteriores estão relacionados ao número de padrões e instâncias a serem armazenados e que são necessários para obter a melhor correspondência e os melhores valores aproximados para a determinação das coordenadas subpixel.

**- 3ª Metodologia: Comparação dos alvos segmentados com os padrões pré-definidos reamostrados.**

Este método consiste em armazenar apenas 5 padrões e reamostrá-los de acordo com a dimensão do alvo segmentado. A dimensão do alvo segmentado é obtida a partir das discrepâncias entre as coordenadas máximas e mínimas em x e y. Com estas coordenadas, determina-se a altura e a largura do alvo segmentado. Com a dimensão do alvo, reamostra os padrões pré-definidos que possuem uma dimensão superior aos alvos segmentados. Este procedimento pode ser usado porque as imagens sofrem uma pequena rotação que pode ser desconsiderada. As vantagens deste método em relação aos dois primeiros estão relacionadas ao número de padrões armazenados e a melhor determinação das coordenadas aproximadas para a localização precisa.

Os resultados destes experimentos são mostrados na Seção 6.4.1

#### 5.2.5.2 Assinatura

A outra técnica de classificação a ser usada é a de assinatura. Esta técnica consiste na comparação entre as assinaturas dos alvos armazenados e segmentados.

As etapas necessárias para a classificação, usando o método de assinatura são:

- Extração da fronteira do alvo pelo método de perseguição de fronteiras. Este método consiste em obter as coordenadas de todos os *pixels* localizados na fronteira do alvo. Nesta etapa, observa-se a lista de alvos gerada na segmentação de imagens. Se o rótulo armazenado na lista for diferente de um (o que significa que o pixel pertence ao fundo), armazenam-se as coordenadas do *pixel* e o número do seu rótulo em uma outra estrutura de lista. A partir do primeiro *pixel*, observam-se os seus *pixels* vizinhos na seguinte ordem: frente, abaixo e atrás. Este procedimento ocorre até que todos os alvos segmentados sejam percorridos. Pixels que não pertencem à fronteira são rotulados como 1, representando fundo.
- Determinação do ponto inicial: O problema em determinar o ponto inicial está relacionado com padrões de formas idênticas que variam em relação à rotação. Como este ponto é determinado pela maior distância do centróide ao ponto pertencente à fronteira, algumas assinaturas geradas são idênticas. Isto pode ser observado na Figura 23 em que os padrões B e E e C e D geram as mesmas assinaturas.

A técnica utilizada, portanto, é determinar o ponto que possui o menor valor no eixo das abscissas e a partir deste procurar o menor valor no eixo das ordenadas. Os pontos iniciais de cada alvo podem ser observados na Figura 24.

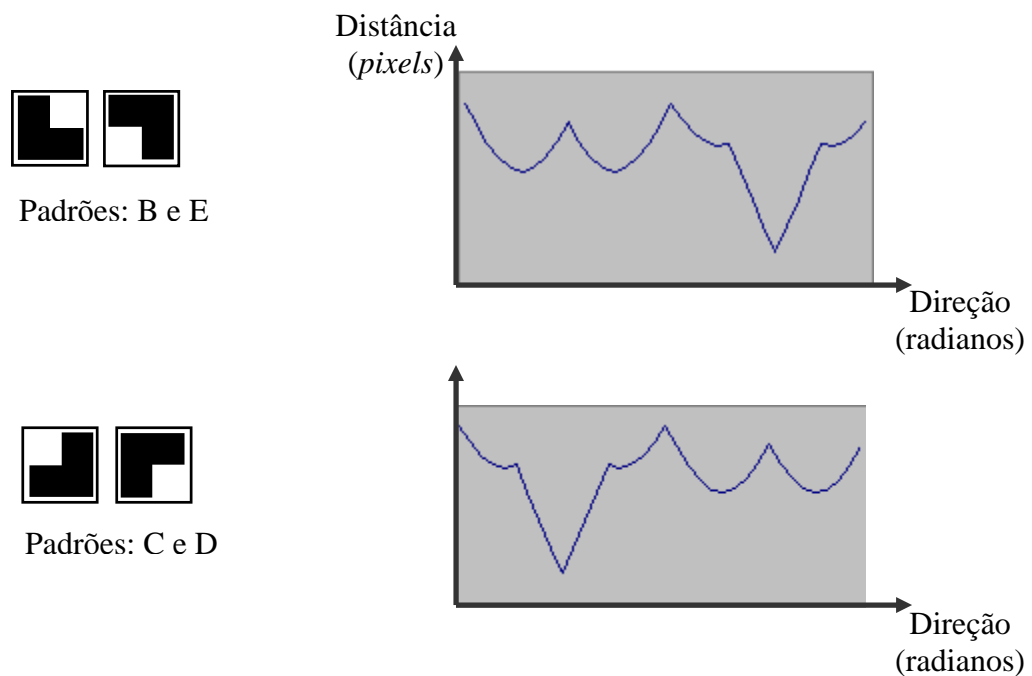


FIGURA 23 - Padrão com diferentes rotações e idênticas assinaturas.




FIGURA 24 – Pontos iniciais dos padrões utilizados.

- Determinação da distância de todos os pontos da fronteira ao centróide e cálculo da sua direção. Como são conhecidas as coordenadas de três pontos (ponto inicial, centróide e ponto da fronteira) (Figura 25), determina-se a direção a partir da fórmula dos cossenos dada por:



$$a^2 = b^2 + c^2 - 2bc \cos \alpha \quad (41)$$

Onde:

$a$  – distância entre o ponto inicial e um ponto pertencente à fronteira;

$b$  – distância entre o ponto inicial e o centróide;

$c$  – distância de um ponto pertencente à fronteira e o centróide;

$\alpha$  - direção a ser calculada.




FIGURA 25 – Direções obtidas dos pontos.

- Normalização do gráfico: o fato dos padrões conterem tamanhos diferentes e conseqüentemente, número de *pixels* diferentes, acarreta na necessidade de realizar a normalização dos mesmos. Isto é feito pela normalização dos dados no intervalo de [0,1].
- Criação do gráfico relacionando a distância em função do ângulo;
- Interpolação dos dados. Esta etapa é necessária porque na determinação da métrica de correlação, há necessidade dos padrões a serem comparados possuírem quantidades de *pixels* idênticas;

- Determinação da discrepância entre as assinaturas, usando a métrica de correlação (Seção 4.2.1). O uso somente da métrica de correlação está relacionado ao tipo de padrões utilizados no trabalho. Como os padrões são semelhantes, as métricas de distância, dispersão e forma não se mostraram adequadas como critério para estabelecer a correspondência.

#### *5.2.6. Localização precisa*

A localização automática precisa dos cantos dos alvos projetados possui a vantagem em relação aos métodos manual ou semi-automático, por diminuir o tempo de resposta do sistema e fornecer uma resposta com precisão subpixel. Nesta etapa, dois métodos de localização precisa foram comparados com o objetivo de refinar a solução obtida na classificação: correspondência por mínimos quadrados e detecção de cantos.

##### *5.2.6.1. Método de correspondência de imagens por mínimos quadrados e reamostragem*

O método de correspondência de imagens por mínimos quadrados consiste em um refinamento na posição dos cantos dos padrões, obtida na etapa de

classificação a uma precisão subpixel. Para isto, determinaram-se os parâmetros radiométricos e geométricos a partir do conhecimento dos níveis de cinza das janelas de referência e de pesquisa de acordo com a Seção 4.1.2. Porém, os resultados obtidos para os parâmetros radiométricos não ofereceram resultados satisfatórios. Uma melhor metodologia, portanto, foi determinar separadamente os parâmetros radiométricos e geométricos. Primeiramente, realizou-se a correção radiométrica da imagem e, posteriormente, fez-se a sua correção geométrica. Ambos os parâmetros foram obtidos por um ajustamento usando o método paramétrico. Após a etapa de mínimos quadrados, realizou-se a reamostragem da janela de pesquisa a partir do conhecimento dos parâmetros obtidos pelo método de correspondência por mínimos quadrados para determinação da posição e dos níveis de cinza da nova imagem. As novas posições dos *pixels* na imagem e seus respectivos níveis de cinza são determinados a partir de uma transformação afim direta e de uma interpolação bilinear.

A aplicação do método de correspondência por mínimos quadrados e a reamostragem ocorrem até o momento em que as correções dos parâmetros geométricos determinados sejam menores que os critérios pré-definidos inicialmente (critérios de convergência = 0.00001).

As coordenadas com precisão subpixel são determinadas a partir do conhecimento das coordenadas aproximadas obtidas no processo de classificação por correlação e os novos parâmetros determinados.

#### 5.2.6.2. Detecção de cantos

A detecção de cantos foi realizada usando o método descrito na Seção 2.9.

Para a detecção de cantos, é necessário realizar previamente a detecção de bordas, neste caso usando-se os operadores de Sobel (Seção 2.8.1.1). Estes operadores permitem a determinação dos gradientes em x e y para os *pixels* centrais após a convolução das máscaras na imagem original.

Para determinação dos gradientes nas molduras na janela do alvo segmentado, uma janela maior na imagem original é selecionada, isto é, para se obter uma matriz 5 x 5 composta de gradientes em x e y, uma subimagem 7 x 7 deve ser selecionada.

O tamanho da subimagem a ser analisada depende do tipo de padrão. Em padrões do tipo A, para todos os cantos, as subimagens podem ser maiores que em outros padrões porque a distância entre os cantos é grande. Este fato tende a garantir uma melhor qualidade subpixel dos cantos do padrão tipo A. Para os alvos B, C, D e E, o tamanho da subimagem a ser analisada depende da posição em que se encontram os alvos. Quanto menor a distância entre os alvos, menor a janela a ser analisada e menor a precisão do detector de cantos na localização dos padrões porque o número de observações é pequeno.

Um problema está relacionado com os padrões pré-definidos, porque, por mais que estes garantam um grande número de cantos com localização precisa para reconstrução, a etapa de aquisição da imagem acaba interferindo na forma dos alvos, arredondando os cantos e dificultando na localização precisa.

Após a realização da detecção de bordas com os operadores de Sobel e, portanto, com o conhecimento dos gradientes na imagem e a posição aproximada de cada vértice do alvo, obtida na classificação dos alvos, determinam-se os cantos da imagem usando a metodologia citada na Seção 2.9.2.

#### 5.2.7. Critério para avaliação do método de localização precisa

Uma vez que as coordenadas reconstruídas a partir dos padrões projetados sobre uma imagem plana deveriam gerar uma superfície plana perfeita, a forma encontrada para avaliar os resultados da calibração dos vetores diretores foi a seguinte:

- Executar o processo de reconstrução sobre a imagem;
- Efetuar a regressão de uma superfície plana sobre as coordenadas 3D reconstruídas; e conseguinte,
- Calcular as discrepâncias entre as coordenadas  $Z$  obtidas na reconstrução e as coordenadas  $\hat{Z}$  calculadas pelo plano ajustado (Equação 42);

$$\hat{Z}(X, Y) = A_{00} + A_{01}Y + A_{10}X \quad (42)$$

Onde:

$Z$  - profundidade dos pontos;

$X, Y$  - coordenadas obtidas da reconstrução;

$A_{00}, A_{01}, A_{10}$  - coeficientes do plano. Estes coeficientes foram obtidos usando o software Surfer 7.0.

- Cálculo do erro médio quadrático.

O método de reconstrução usado neste trabalho é uma implementação da modelagem matemática desenvolvida na primeira versão do sistema de reconstrução (TOMMASELLI, 1997).

A reconstrução da superfície é realizada conhecendo-se cada vetor diretor dos cantos dos alvos e suas respectivas coordenadas subpixel. Os vetores diretores dos vértices dos alvos são calculados por uma calibração do projetor, a partir do conhecimento das coordenadas subpixel determinadas nos métodos de localização precisa, da orientação interior, da orientação exterior, das coordenadas do projetor e dos valores aproximados dos vetores diretores. Os parâmetros de orientação interior e de orientação exterior e as coordenadas do projetor são obtidos pela calibração da câmara. Maiores detalhes de todo o processo de reconstrução podem ser vistos em Reiss e Tommaselli (2004).

## **CAPÍTULO VI**

### **6. DESENVOLVIMENTO E IMPLEMENTAÇÃO**

Para atender aos objetivos deste trabalho, alguns programas foram implementados em Linguagem C/C++ como: geração automática de padrões, limiarização local, segmentação por crescimento de regiões, extração de fronteiras, correspondência por área, assinatura e detecção de bordas. Além disto, vale ressaltar que os programas de segmentação por crescimento de regiões e limiarização foram implementados pelo Msc. Mário Luiz Lopes Reiss. As funções implementadas podem ser encontradas na biblioteca UPTK, que está sendo desenvolvida pelo Departamento de Cartografia da FCT/Unesp (TOMMASELLI, 2003).

#### **6.1. Geração automática de padrões**

O programa de geração automática de padrões tem como resultado a criação de um padrão composto pela combinação de cinco padrões primitivos (Figura 18). Como mencionado anteriormente, esta combinação de padrões possui algumas restrições para ser realizada. Estes padrões primitivos foram combinados em matrizes, gerando-se uma malha. A partir de um processo fotográfico foram

então gerados fotolitos. No total, dez fotolitos foram criados, modificando-se o tamanho do padrão e o espaçamento entre os mesmos (Figura 26).

O fotolito projetado neste trabalho possui padrões com tamanho de 9 *pixels*. x 9 *pixels*. e com espaçamento de 7 *pixels* entre os padrões (Figura 27).




FIGURA 26 – Exemplo de uma imagem de padrões.




FIGURA 27 - Dimensão dos padrões projetados em *pixel*.



## 6.2. Limiarização local

Inicialmente, dois métodos foram implementados para solucionar este problema: método de expansão do histograma e método de transformação local baseado nas propriedades de intensidades da média e de desvio-padrão de *pixels* (Seção 2.5). Estes métodos, entretanto, não proporcionaram um resultado satisfatório como pode ser observado na Figura 28.




FIGURA 28 – Resultados da limiarização. (a) Imagem original; (b) Método de expansão do histograma; (c) Método de transformação local.

O problema do método de expansão do histograma está relacionado a este ser um método global e, portanto, determina um único limiar por toda a imagem.

O método de transformação local garante um melhor resultado que o método de expansão do histograma por este método ser local, porém, em procedimentos totalmente automáticos, este método possui a restrição em relação à

constante  $k$ , pela necessidade de informá-la inicialmente e esta ser dependente da imagem original a ser usada.

Portanto, como os métodos anteriores não garantiram resultados satisfatórios, uma nova metodologia foi sugerida. Esta metodologia consistiu na implementação de uma limiarização local (Seção 2.6.3) comparando dois operadores de limiarização automática: Otsu (Seção 2.6.1) e Pun (Seção 2.6.2). Neste método de limiarização informa-se o tamanho da máscara a ser percorrida na imagem e o método de limiarização desejado. Para cada percurso da máscara na imagem, um limiar é determinado a partir do método de Otsu ou de Pun e aplicado à imagem, em função da região central da máscara. Os *pixels* com valores abaixo do limiar determinado pelos métodos de Otsu ou de Pun recebem nível de brilho zero e os *pixels* com níveis de cinza superiores a este valor, permanecem com o mesmo valor de nível de cinza.

Os resultados deste processo podem ser observados na Figura 29. Como se podem perceber visualmente, ambos os métodos de limiarização conseguiram eliminar completamente os ruídos do fundo, sem prejudicar o processo de reconhecimento. Além disto, foram comparados três diferentes tamanhos de máscaras (3x3, 5x5 e 7x7). A partir de testes, observou-se que a máscara 3x3 usando o método de Otsu proporcionou melhores resultados aliados a um menor custo computacional. Conseqüentemente, pensando no custo computacional, decidiu-se usar o método de Otsu. Outra maneira de comparar os métodos de limiarização é observar os resultados das segmentações, verificando o número de alvos perdidos e suas respectivas formas.




FIGURA 29 - (a) Imagem original (tomada de um dorso humano) com o sistema de luz estruturada; (b) Parte da imagem original; (c) (d) Limiarização com o método de Otsu local; (e) (f) Limiarização com Pun local (REISS e TOMMASELLI, 2004).

### 6.3. Segmentação

A segmentação consiste em subdividir uma imagem em regiões homogêneas usando critérios de similaridade. Neste caso, o método de segmentação usado foi por crescimento de regiões, usando como critério de similaridade os níveis de cinza. Neste processo de segmentação de regiões, o fundo da imagem recebe o rótulo 1 e os padrões são rotulados com números desde 2 até o número de padrões segmentados. Após a segmentação de um alvo, adiciona-se +1 ao número do rótulo. Simultaneamente à segmentação, são calculadas as coordenadas dos centros de massa de cada padrão. As coordenadas dos *pixels* segmentados e o rótulo de cada padrão são armazenados em uma lista para ser usada nas próximas etapas. Os resultados da etapa de segmentação podem ser observados na Figura 30.




FIGURA 30 – Resultados de imagens segmentadas. (a) Todos os alvos foram segmentados. (b) Alguns alvos não foram segmentados.

Como pode ser observado na Figura 30a, todos os alvos foram segmentados. Na Figura 30b, entretanto, alguns alvos não foram segmentados. Isto

ocorreu porque foram feitas algumas considerações a respeito do tamanho do alvo, isto é, baseado na relação da distância focal da câmara com as distâncias máxima e mínima do centro perspectivo da câmara à superfície do objeto, foi possível determinar a quantidade aproximada de *pixels* de cada padrão. Assim, alvos com quantidade de *pixels* não pertencentes ao intervalo estabelecido são eliminados após a segmentação. Esta restrição ocorre para não adquirir *pixels* que sejam ruídos na imagem ou alvos muito grandes que são consequência da deformação dos alvos no objeto ou junção de alvos, proporcionando um reconhecimento equivocado posteriormente.

#### **6.4. Classificação**

A partir da imagem segmentada, inicia-se uma das etapas fundamentais para a realização da reconstrução: a classificação dos alvos. Esta etapa é importante porque os seus resultados interferem completamente na localização precisa e posterior reconstrução pois as coordenadas aproximadas dos cantos dos alvos são determinadas nesta etapa. A classificação de alvos objetiva informar a melhor correspondência do alvo segmentado quando comparado com os padrões.

Nesta etapa de classificação, dois métodos de correspondência foram comparados: a correspondência por padrão e a assinatura.

#### 6.4.1. Correspondência por correlação

A correspondência por correlação consiste na comparação entre os níveis de cinza de duas imagens sobrepostas usando uma função desejada. Várias funções podem ser utilizadas, porém, neste trabalho foram comparadas cinco delas: erro, erro quadrático, correlação cruzada, covariância cruzada e covariância cruzada modificada. A partir de testes realizados, observou-se que a função covariância cruzada modificada é a que apresentou melhores resultados. Os resultados das outras funções acarretaram em erros de um e dois *pixels* em relação ao valor exato nas imagens testadas. Porém, esta função possui uma desvantagem em relação às outras funções: maior custo computacional porque a função é mais complexa. Mesmo havendo o inconveniente do custo computacional, decidiu-se usar esta função para a classificação dos alvos porque as imagens a serem comparadas são pequenas e não prejudicariam o rendimento computacional.

Na função de covariância cruzada modificada, a melhor correspondência será aquela em que o coeficiente de correlação for o mais próximo da unidade. Porém, se a imagem sofre rotações, variações na escala ou perda de parte do alvo, uma falsa correspondência pode ocorrer ou o coeficiente de correlação ser tão pequeno que não possa ser considerado. A partir de testes realizados, observou-se que um limiar para este coeficiente de correlação poderia ser 0.7 porque garantiria uma classificação correta para as imagens usadas e não provocaria uma perda significativa dos alvos.

Portanto, três metodologias foram comparadas: comparação dos alvos segmentados com os padrões pré-definidos e com as suas instâncias

armazenadas, comparação dos alvos segmentados com os padrões pré-definidos suavizados e com as suas instâncias armazenadas suavizadas, comparação dos alvos segmentados com os padrões pré-definidos reamostrados.

#### 6.4.4.1. Comparação dos alvos segmentados com os padrões pré-definidos e com as suas instâncias armazenadas

O método consiste, portanto, na comparação de todos os alvos segmentados na imagem com os cinco padrões armazenados e suas instâncias geradas por modificação em relação à escala. No total são 45 padrões binários armazenados. A variação de escala foi determinada a partir de observações empíricas realizadas na imagem. Além das imagens de cada padrão, foram armazenadas em uma estrutura de lista as coordenadas em *pixels* dos cantos, que são usadas posteriormente como valores aproximados na localização precisa. O resultado deste reconhecimento pode ser observado na Figura 31. Na Figura 31b, os alvos encontram-se sem rotação porque se concentram na parte central do cilindro, enquanto que na Figura 31d, os alvos estão distorcidos.

Por uma questão de visualização, os alvos detectados foram pintados em cores diferentes: padrão A (preto); padrão B (azul); padrão C (vermelho); padrão D (verde) e padrão E (roxo).

Neste experimento, todos os alvos foram detectados corretamente (Figura 31c). Os alvos que não foram detectados apresentavam-se parcialmente incompletos ou deformados pela superfície e não geraram um coeficiente de

correlação maior que o pré-definido como limiar (0.7) com nenhum dos padrões ou suas instâncias.

Uma dificuldade observada foi a detecção de alvos em escalas diferentes em x e y e distorcidos (Figura 31d), já que não é recomendável gerar muitos padrões instanciados, porque isto aumentaria o custo computacional. Nestes casos, como os alvos sofrem modificações diferentes em escalas x e y, uma detecção correta pode ocorrer, porém, as coordenadas aproximadas não são confiáveis.

Vale ressaltar que este procedimento proporciona bons resultados porque é pequena a percentagem de alvos não reconhecidos (em torno de 15%). Isto garante um grande número de vértices para a localização precisa e tende a garantir uma melhor reconstrução do objeto se comparada com a reconstrução obtida apenas pelo centro de massa de cada alvo. Um exemplo de classificação de todos os alvos da imagem pode ser observado nas Figuras 32 e 33.



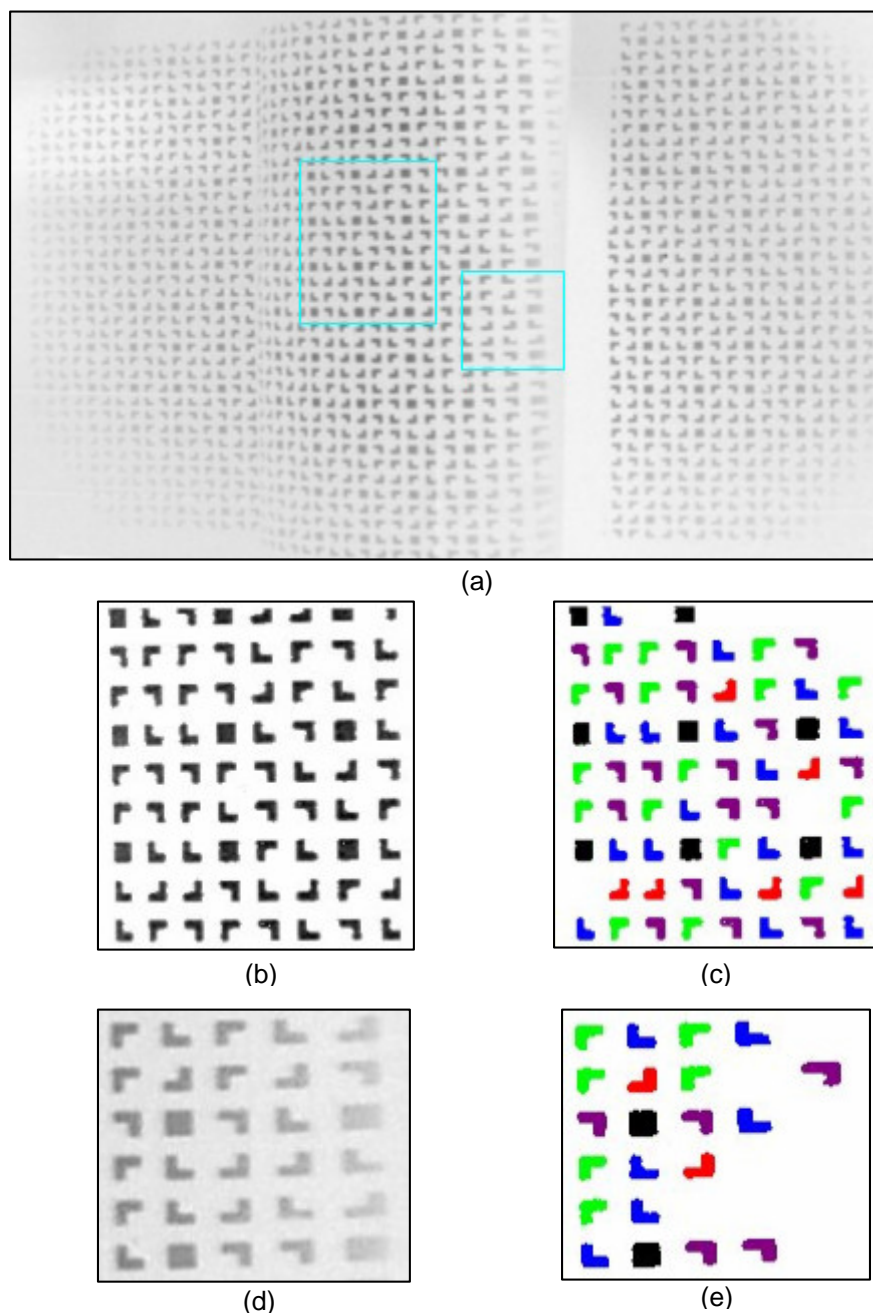


FIGURA 31 – Resultados da correspondência por correlação usando padrões binários (imagens invertidas). (a) Imagem dos alvos projetados em um cilindro; (b) Imagem realçada de uma imagem sem variação de rotação; (c) Classificação dos alvos para a imagem com padrões projetados distorcidos; (d) Imagem realçada de uma imagem com variação na rotação; (e) Classificação dos alvos para a imagem com padrões projetados distorcidos.




FIGURA 32 - Classificação dos alvos de um cilindro após a segmentação (imagem invertida).




FIGURA 33 - Classificação dos alvos após a segmentação de um dorso humano  
(imagem invertida).

Pensando em melhorar os resultados da classificação por correlação, usaram-se os mesmos padrões armazenados e suas instâncias suavizadas pela média.

#### 6.4.4.2. Comparação dos alvos segmentados com os padrões pré-definidos suavizados e com as suas instâncias suavizadas armazenados

Esta escolha foi feita observando como eram os alvos projetados, já que a correspondência com alvos binários poderia ser prejudicada por causa da variação entre os níveis de cinza entre as imagens armazenadas e segmentadas. Os resultados após estas considerações podem ser observados na Figura 34.

Como pode ser observada na Figura 34, a correspondência por correlação usando padrões armazenados suavizados garantiu melhores resultados que o método usando imagens binárias. Em imagens com pouca variação na rotação, este método conseguiu classificar aproximadamente 94% dos alvos segmentados enquanto em imagens com variação na rotação, 90% dos alvos foram classificados corretamente.

Mesmo considerando que os resultados eram bons com as metodologias anteriores, decidiu-se refinar ainda mais os resultados. Como os alvos projetados sofrem uma variação diferente de escala em x e y, o alvo segmentado poderia ser correlacionado com um padrão de diferente tamanho e proporcionar coordenadas aproximadas incorretas para a localização precisa. Uma possibilidade seria aumentar o número de padrões armazenados, porém, isto aumentaria o custo

computacional. Uma melhor maneira, foi trabalhar com padrões reamostrados em tempo real.

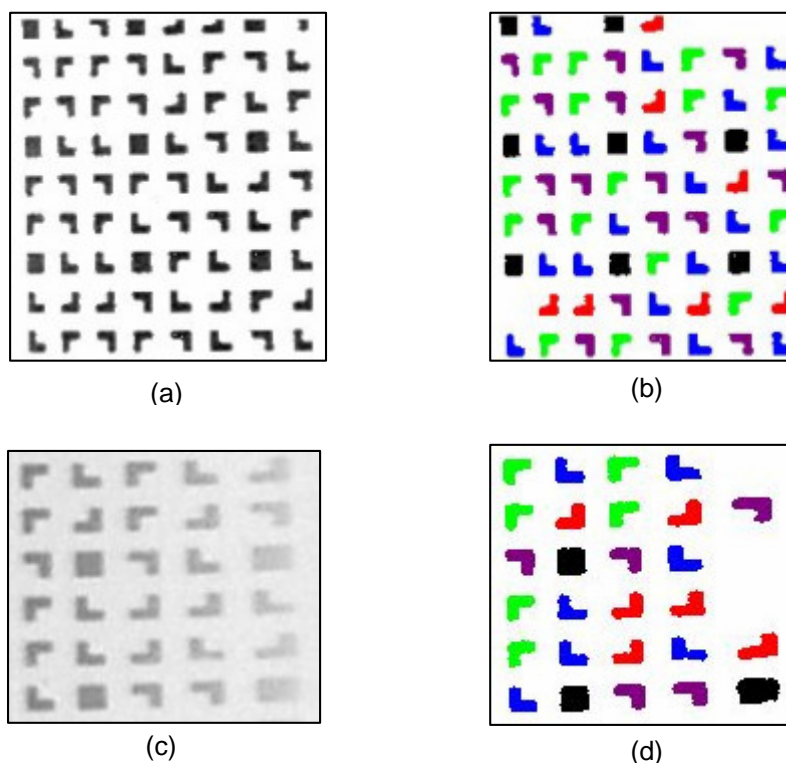


FIGURA 34 – Resultados da correspondência por correlação usando padrões suavizados pela média (imagens invertidas) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.

#### 6.4.4.3. Comparação dos alvos segmentados com os padrões pré-definidos reamostrados

Esta metodologia consiste armazenar apenas os cinco padrões primitivos e a partir do conhecimento da dimensão dos alvos segmentados,

reamostrá-los em tempo real. Neste caso, três experimentos foram realizados: reamostrando padrões primitivos com dimensão 23 x 23 *pixels*, 90 x 90 *pixels* (com moldura) e 90 x 90 *pixels* (sem moldura).

**- 1º Experimento: Reamostrando padrões primitivos com dimensão 23 x 23 *pixels***

Esta dimensão dos padrões armazenados foi escolhida empiricamente, a partir de observações realizadas na imagem. A dimensão dos alvos segmentados foi obtida a partir da diferença entre as coordenadas máximas e mínimas de cada alvo. Este procedimento pode ser usado, neste caso, porque as imagens usadas possuem uma pequena variação da rotação. O método usado para a reamostragem dos alvos nas imagens foi o método de interpolação bilinear (Seção 4.1.2). Para este tipo de método, aproximadamente 96% dos alvos conseguiram ser classificados corretamente para imagens com pequena rotação e em regiões com um alto gradiente, todos os alvos foram classificados (Figura 35). É importante ressaltar que este procedimento conseguiu classificar corretamente mesmo alguns alvos estando incompletos.

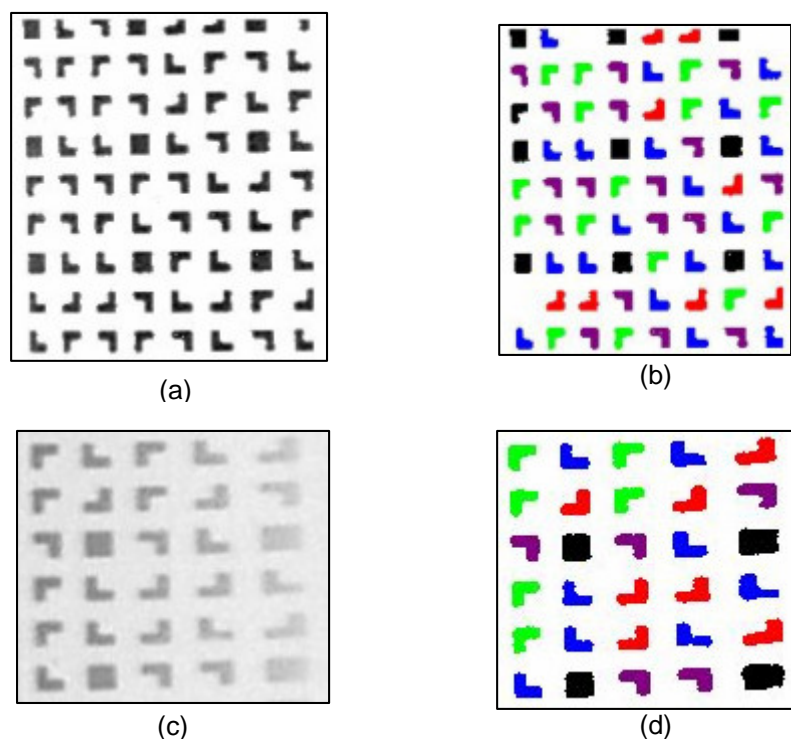


FIGURA 35 – Resultados da correspondência por correlação usando padrões reamostrados (Padrões 23 *pixels* x 23 *pixels*) (imagens invertidas) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.

Posteriormente, observou-se, adicionalmente, que esta técnica de classificação poderia ser melhorada ainda mais a partir do uso de padrões com dimensão proporcional ao do alvo projetado ao invés da escolha empírica de sua dimensão, com base apenas na observação dos alvos na imagem. Neste caso, a dimensão escolhida para os padrões armazenados foi de 90 *pixels* x 90 *pixels*.

**- 2º Experimento: Reamostrando padrões primitivos com dimensão 90 x 90 pixels (sem moldura)**

Neste experimento, resolveu-se reamostrar apenas a parte branca do alvo e posteriormente, inserir a moldura preta com dimensão de 2 *pixels* (Figura 36). Os resultados obtidos com este método podem ser observados na Figura 37.




FIGURA 36 – Reamostragem dos padrões primitivos sem moldura.



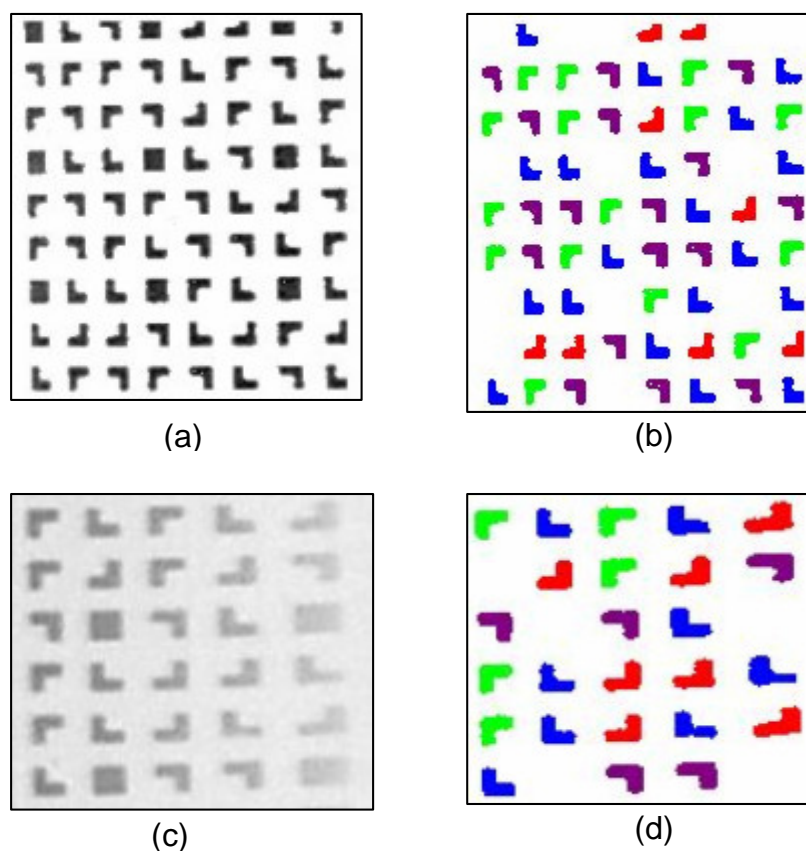


FIGURA 37 – Resultados da correspondência por correlação usando padrões reamostrados sem bordas (Padrões 90 *pixels* x 90 *pixels*) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.

**- 3º Experimento: Reamostrando padrões primitivos com dimensão 90 x 90 *pixels* (com moldura)**

Como o resultado obtido e mostrado na Figura 37 não proporcionou os resultados esperados, decidiu-se usar padrões com dimensão proporcional ao do alvo projetado (90 *pixels* x 90 *pixels*). Porém, ao invés de reamostrar o alvo sem as



molduras, reamostrou-os com molduras de dimensão 2 *pixels*. Os resultados desta metodologia podem ser observados na Figura 38.

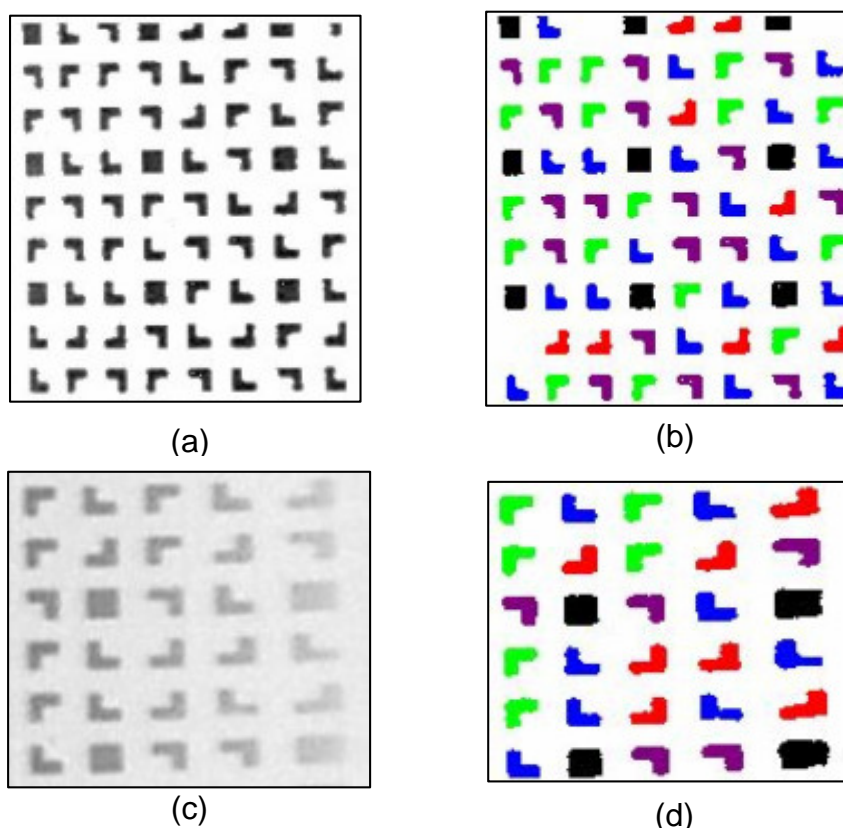


FIGURA 38 – Resultados da correspondência por correlação usando padrões reamostrados usando molduras (Padrões 90 *pixels* x 90 *pixels*) (a) Imagem realçada de uma imagem sem variação de rotação; (b) Classificação dos alvos para a imagem sem variação da rotação; (c) Imagem realçada de uma imagem com padrões projetados distorcidos; (d) Classificação dos alvos para a imagem com padrões projetados distorcidos.


A partir destes experimentos realizados pode-se observar que os métodos usando a reamostragem por interpolação bilinear em tempo real proporcionaram melhores resultados. Além disso, usando o método de reamostragem por interpolação bilinear, pode-se diminuir o limiar até valores como 0.5, e mesmo assim o procedimento ainda consegue correlacionar perfeitamente

sem muitas perdas de alvos. Verificou-se, ainda, que não é viável reamostrar apenas a imagem sem as molduras e depois inseri-las. Este procedimento faz com que a imagem não sofra uma suavização e os valores dos coeficientes de correlação sejam inferiores aos valores estipulados anteriormente. Realizando este mesmo procedimento com os alvos pré-definidos, a perda de alvos é mais elevada e ainda, alguns alvos já começam a ser correlacionados erroneamente. Por outro lado, o método de classificação usando alvos pré-definidos também proporcionou bons resultados e poderia ser melhorado ainda mais, se o número de padrões armazenados fosse maior. Porém, isso não é viável porque aumentaria muito o custo computacional.

#### 6.4.2. Assinatura

A assinatura de um alvo consiste de um gráfico relacionando a distância e a direção de cada pixel pertencente à sua fronteira. Para determinar os pixels que fazem parte da fronteira, uma extração é realizada usando o método de perseguição de fronteiras (Figura 39). Neste método, uma estrutura de lista é criada composta do número do rótulo do alvo e as respectivas coordenadas dos pixels pertencentes à fronteira.

Como os alvos encontram-se com dimensão pequena, a segmentação, em alguns casos, não proporciona resultados satisfatórios, interferindo na extração da fronteira e prejudicando na detecção pelo método da assinatura (ver Figura 39).



(a)



(b)

FIGURA 39 – Extração de fronteiras usando o método de perseguição de fronteiras.

(a) Extração de fronteiras dos alvos projetados em um cilindro;

(b) Detalhe da imagem com as fronteiras dos alvos extraídos.

Para a comparação entre as assinaturas armazenadas (relacionadas aos padrões) e assinaturas geradas (referentes aos alvos segmentados), resolveu-se primeiramente, armazenar as distâncias e as direções em um arquivo com extensão *.dat*. Porém, o usuário poderia querer alterar os padrões a serem comparados e, para isto, decidiu-se determinar a assinatura dos padrões

armazenados juntamente com as dos alvos segmentados. As características das assinaturas de cada padrão armazenado podem ser vistas na Figura 40.

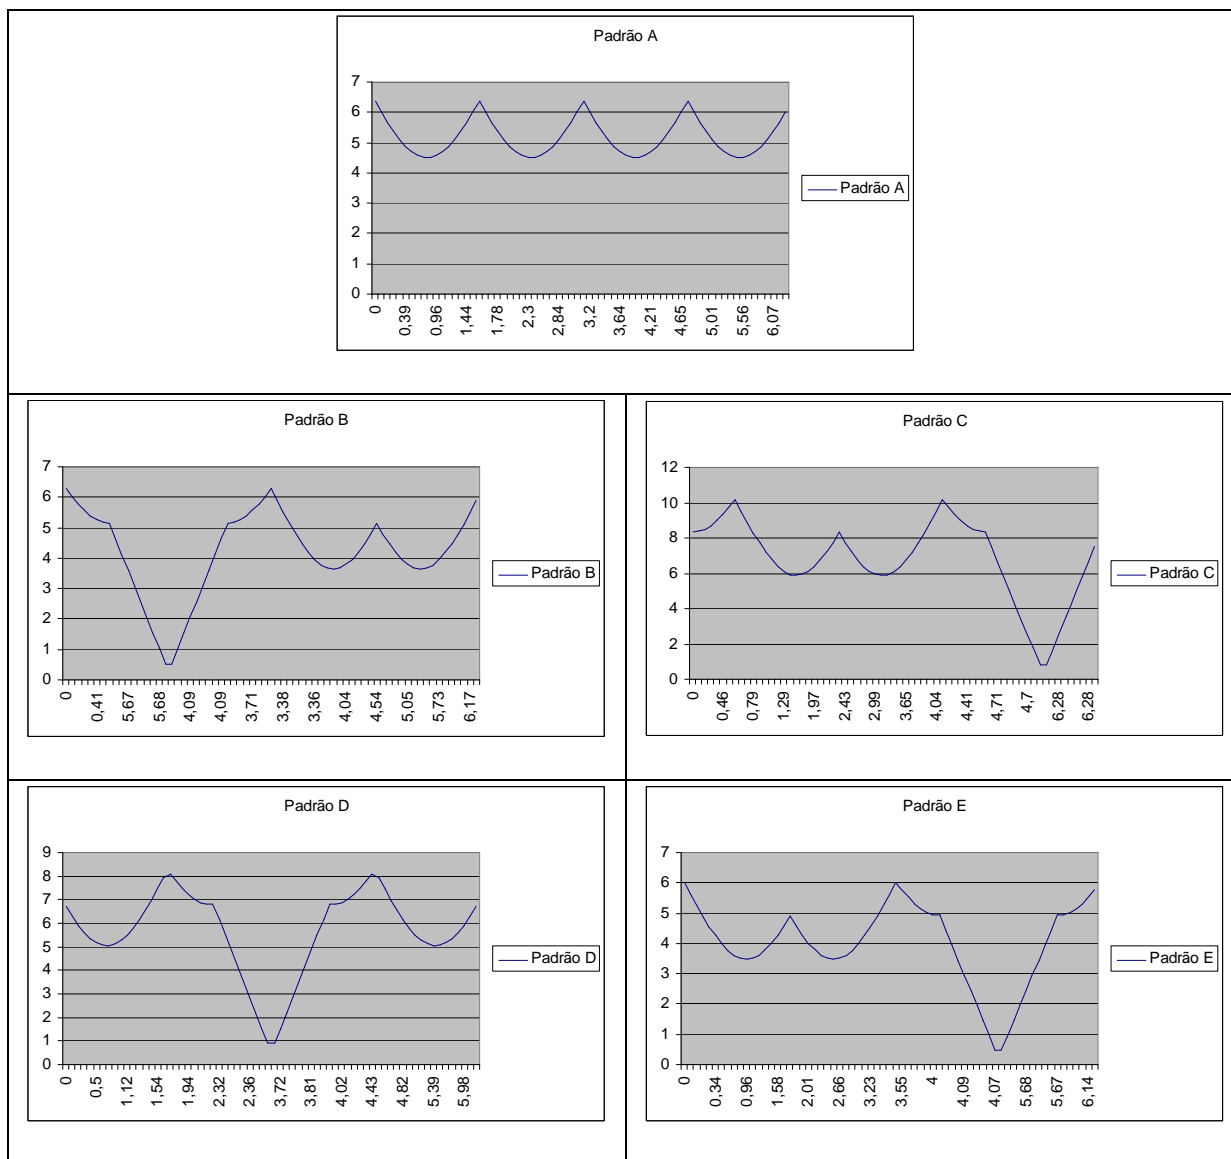


FIGURA 40 - Assinatura dos padrões armazenados.

Como dito anteriormente, estes gráficos são gerados a partir do conhecimento das distâncias e das direções. As direções são obtidas a partir do conhecimento de três pontos: dois pontos da fronteira e o centróide usando a fórmula dos cossenos. Portanto, este gráfico é construído com as direções (em função das distâncias) no eixo das abscissas e as distâncias no eixo das ordenadas

(em função das coordenadas dos pixels pertencentes à fronteira e o centro de massa do padrão).

Para comparar as assinaturas geradas e armazenadas, quatro erros métricos foram calculados: erro de distância, erro de forma, erro de dispersão e erro de correlação. Para isto, necessitou-se realizar uma subamostragem dos dados para determinar o erro de correlação porque na determinação deste erro, necessita-se que tanto o padrão armazenado quanto o alvo gerado tenham a mesma quantidade de *pixels* na fronteira. A subamostragem foi realizada fazendo com que o alvo com maior quantidade de *pixels* na fronteira tivesse no final, um número idêntico ao outro alvo. O resultado desta subamostragem pode ser observado na Figura 41. Após testes realizados, observou-se que os erros métricos de distância, dispersão e forma não poderiam ser usados para os tipos de alvos escolhidos neste trabalho porque os alvos B, C, D e E são idênticos, variando apenas na rotação. Portanto, preferiu-se usar apenas a métrica de correlação.

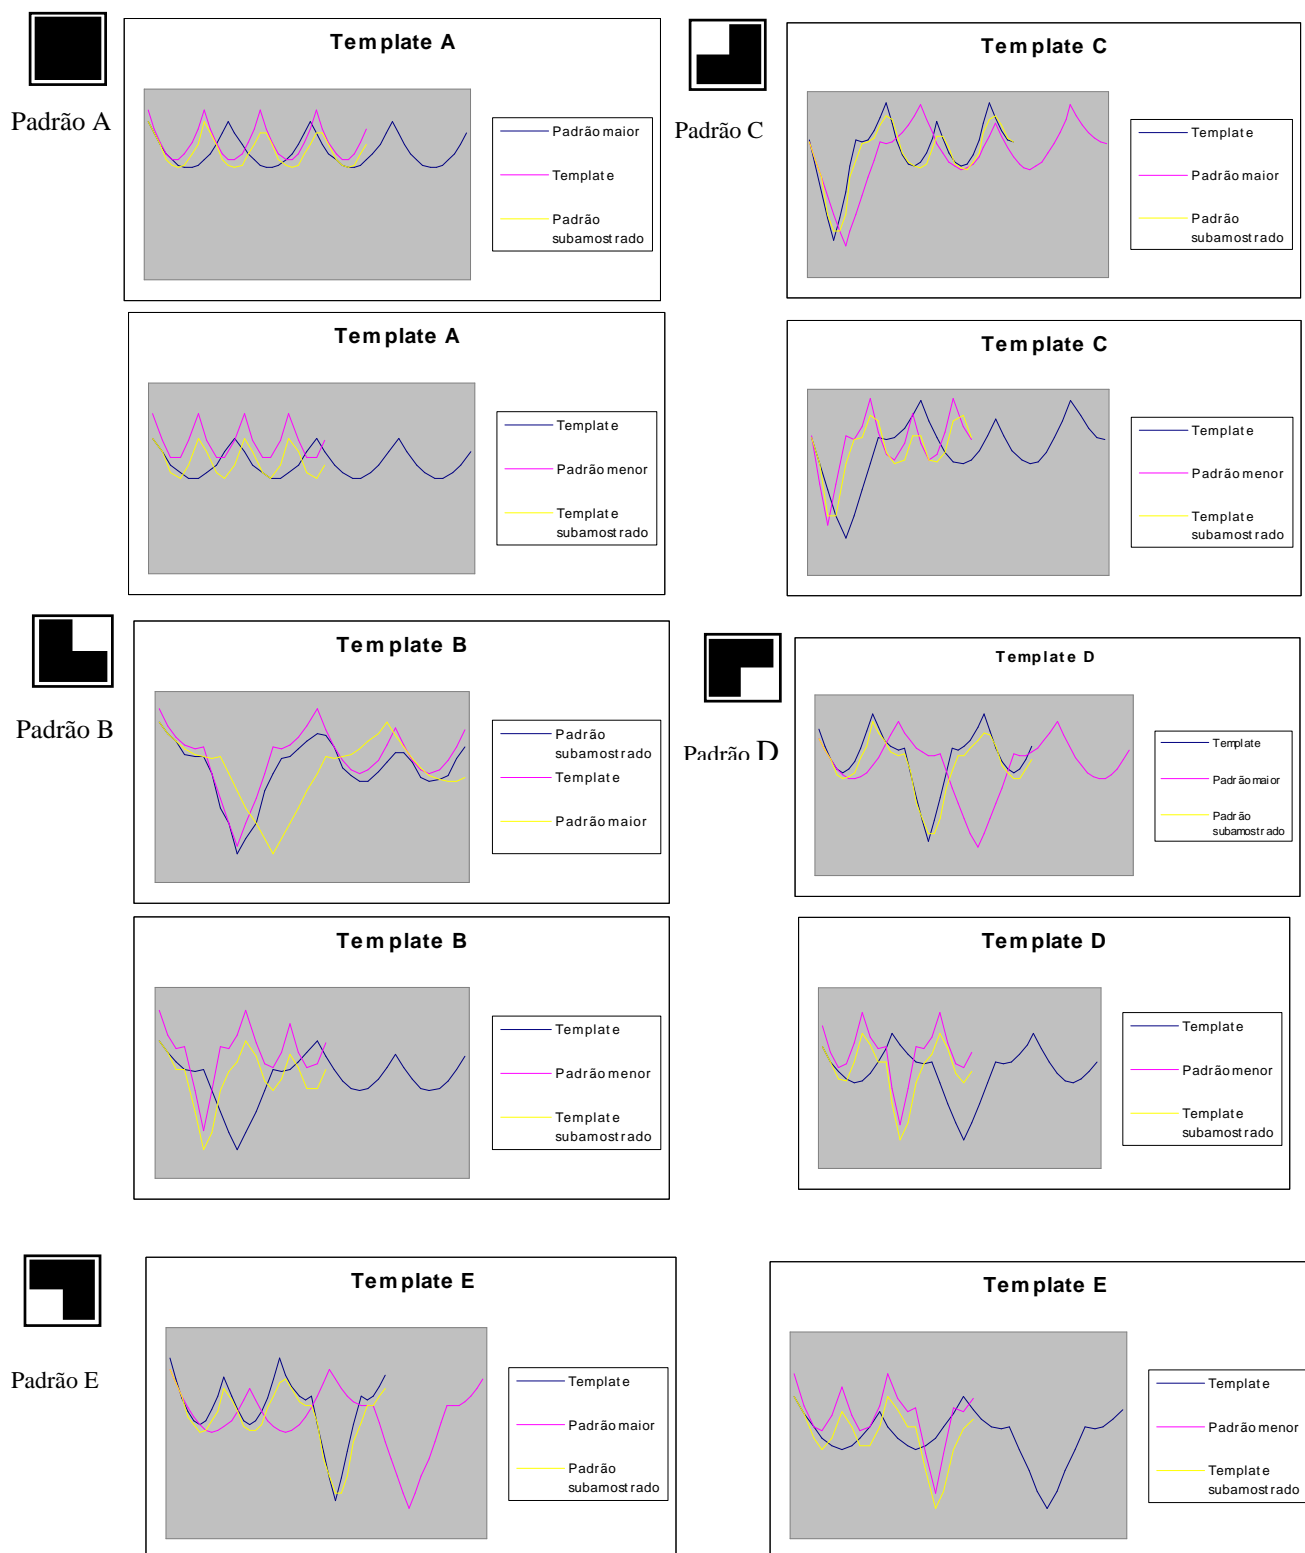


FIGURA 41 – Assinaturas dos padrões e dos alvos segmentados.

A Figura 41 mostra os resultados da subamostragem da assinatura. São mostrados dois gráficos para cada tipo de alvo e cada gráfico contém três

assinaturas. Os gráficos mostram a assinatura do padrão, a assinatura do alvo segmentado e a assinatura do padrão ou do alvo subamostrado, dependendo da quantidade de *pixels*.

A partir destes gráficos, pode-se perceber a similaridade das assinaturas dos alvos após a reamostragem. O problema de compatibilização das assinaturas por meio de reamostragem é complicado, pois ao reamostrar pode-se perder informação. Na Figura 41 podem ser vistos padrões nos quais os picos são achatados, em função da reamostragem. Os resultados obtidos com o método de assinatura usando a subamostragem dos dados proporcionaram uma classificação correta de aproximadamente 67% dos alvos em regiões com pequena variação na rotação (centro do cilindro) e 55% em regiões com alto gradiente. Os alvos vermelhos na Figura 42 indicam que estes não foram classificados.




FIGURA 42 – Resultado da classificação usando o método de assinatura.

Pensando em melhorar estes resultados, decidiu-se realizar uma superamostragem dos dados com uma frequência de, no mínimo, duas vezes

superior a maior frequência para não haver perda de dados. Porém, os resultados obtidos não proporcionaram melhores resultados que a subamostragem dos dados.

## **6.5. Localização precisa**


A etapa de localização precisa possui como objetivo obter as coordenadas dos cantos dos alvos projetados com precisão subpixel. Os valores aproximados para as coordenadas com precisão *pixel* foram obtidos após a classificação dos alvos. Para realizar esta etapa, dois métodos foram comparados: correlação por mínimos quadrados e detecção de cantos.

### *6.5.1. Correspondência de imagens por mínimos quadrados*

A correspondência de imagens por mínimos quadrados consiste em refinar a solução obtida na detecção de alvos a partir da determinação dos parâmetros geométricos usando o ajustamento baseado no método paramétrico (Seção 4.1.2). Neste caso, dois experimentos foram comparados: um usando padrões pré-definidos e o outro com padrões reamostrados.

O resultado do experimento referente à localização precisa usando alvos pré-definidos pode ser observado na Figura 43.






Cantos obtidos da classificação – azul  
Cantos com coordenadas subpixel – cor-de-rosa

FIGURA 43 - Localização precisa dos alvos usando padrões pré-definidos.

Na Figura 43 podem ser observados os cantos plotados a partir dos valores aproximados, resultantes do processo de classificação de alvos como círculos amarelo, e os cantos com coordenadas subpixel em verde.

Como pode ser observada na Figura 43, a localização precisa foi dificultada porque os valores aproximados resultantes do processo de detecção usando padrões pré-definidos, não foram precisos o suficiente. Isto ocorre porque há variações de escalas diferentes em x e y.

Para melhorar a localização precisa, decidiu-se gerar apenas cinco padrões para serem comparados. Neste caso, como se conhecia a altura e a largura do alvo, fez-se uma reamostragem dos alvos a partir de uma interpolação bilinear. Como as imagens usadas não possuíam uma rotação muito elevada, este método de reamostragem do alvo a partir do conhecimento da altura e da largura não acarretou em problemas. A localização precisa, neste caso, forneceu melhores resultados porque foram melhores as coordenadas aproximadas com precisão *pixel* (Figura 44).




Cantos obtidos da classificação – azul  
Cantos com precisão subpixel - amarelo

FIGURA 44 – Localização precisa usando o método de reamostragem dos padrões.

#### 6.5.2. Detecção de cantos

Antes de detectar os vértices com precisão subpixel, foi necessário determinar os gradientes da imagem. Para isto, foram usados os operadores de Sobel como descritos na Seção 2.8.1.1. Para cada convolução das máscaras na subimagem, os gradientes em x e y para o *pixel* central são determinados a partir de uma maior imagem recortada. Por exemplo, se a máscara de gradientes a ser determinada é 5 *pixels* x 5 *pixels*, seleciona-se uma imagem 7 *pixels* x 7 *pixels*. Com todos os gradientes em x e y da imagem obtidos e com a localização aproximada dos vértices dos alvos obtida pela correlação no momento da classificação, determinou-se os cantos dos alvos com precisão subpixel. As coordenadas subpixel foram obtidas a partir de um programa baseado em Galo e Tozzi (2002). Como a reamostragem por interpolação bilinear proporcionou melhores resultados que a

utilização de padrões pré-definidos, resolveu-se fazer experimentos apenas com a detecção de cantos usando padrões reamostrados em tempo real (Figura 45).



Cantos obtidos da classificação – amarelo.  
Cantos com precisão subpixel – vermelho.

FIGURA 45 – Localização precisa por detecção de cantos usando padrões reamostrados.

Como visualmente é difícil afirmar qual o melhor método de localização precisa, resolveu-se realizar a reconstrução de duas linhas selecionadas de uma imagem (linhas 14 e 15) (Figura 46). Inicialmente, escolheu-se uma imagem de um plano com quatro diferentes orientações. Para cada imagem, determinaram-se as coordenadas de todos os vértices usando três métodos: correspondência por mínimos quadrados usando padrões pré-definidos e suas instâncias; correspondência por mínimos quadrados reamostrando em tempo real os padrões armazenados; e, detecção de cantos reamostrando os padrões armazenados. A reamostragem destes padrões é feita a partir do conhecimento da altura e da largura do alvo segmentado. Com as coordenadas determinadas, criaram-se três arquivos, um para cada método. Cada arquivo é composto pelo nome da imagem,

identificação do padrão e as coordenadas de imagem de cada vértice (Tabela 6). Além disso, as coordenadas do centro de massa dos demais alvos foram usadas.




FIGURA 46 – Uma das quatro imagens usadas para calibração da câmara.

TABELA 6 – Exemplo de saída do reconhecimento de padrões.

Nome da imagem sem extensão	Identificador do padrão	Coordenadas ( <i>pixel</i> )	
		X	Y
DCP_2517	145413	1377,54	530,54

O identificador do padrão é dividido em quatro partes: os quatro primeiros dígitos equivalem à linha e a coluna do padrão, respectivamente. O quinto dígito está relacionado ao número do vértice do padrão e o último ao tipo do padrão. A numeração dos vértices de cada padrão inicia-se no ponto inicial mostrado na Figura 24 e continua no sentido horário. Em relação ao tipo do padrão, a numeração é a seguinte: A (1), B (2), C (3), D (4) e E (5).

Para a realização da reconstrução, dois procedimentos são necessários anteriormente: calibração da câmara e calibração do projetor.

A calibração do projetor consiste na determinação dos vetores diretores de cada padrão projetado e das coordenadas do projetor no referencial da câmara ( $X_p$ ,  $Y_p$  e  $Z_p$ ). Para realização desta etapa, necessita-se:

- Determinação dos parâmetros de orientação interior a partir da calibração de câmara;
- Resseção espacial para determinação dos parâmetros de orientação exterior. Esta etapa depende das coordenadas dos alvos fixados na placa de calibração (pontos de apoio – sistema global) e das coordenadas dos mesmos pontos na imagem;
- Calibração do projetor: nesta etapa, calculam-se, inicialmente, as coordenadas dos pontos projetados no referencial global, usando suas coordenadas imagem, os parâmetros de orientação exterior obtidos na etapa anterior e a equação de colinearidade inversa. Com várias nuvens de pontos, que correspondem a vários planos de projeção, calculam-se os elementos do projetor (REISS e TOMMASELLI, 2004).

Com as coordenadas  $X$ ,  $Y$  e  $Z$  no espaço objeto de cada ponto, determina-se a coordenada  $\hat{Z}$  a partir do ajuste de um plano (Seção 5.2.7). Calculam-se, então, as discrepâncias entre as coordenadas  $Z$  obtidas da reconstrução e as coordenadas  $\hat{Z}$  obtidas pela equação do plano ajustado, e, posteriormente, o erro médio quadrático para todas as discrepâncias. O programa de reconstrução 3D foi baseado na modelagem matemática desenvolvida na primeira versão do sistema de reconstrução (TOMMASELLI, 1997).

Como os alvos do tipo A oferecem uma detecção e uma localização precisa melhor que outros alvos, decidiu-se realizar dois experimentos. O primeiro experimento consiste em determinar o erro médio quadrático usando apenas os

vértices dos padrões do tipo A enquanto o segundo experimento, calcula o erro médio quadrático para os vértices de todos os alvos.

Os erros médios quadráticos determinados por cada método no experimento um podem ser observados na Tabela 7.

TABELA 7 - Métodos usados e respectivos erros médios quadrático usando apenas os alvos do tipo A.

<b>Método usado</b>	<b>Coeficientes da regressão polinomial</b>			<b>EMQ (mm)</b>	<b>Erro máximo (mm)</b>	<b>Erro mínimo (mm)</b>
	<b>A00</b>	<b>A01</b>	<b>A10</b>			
<b>MQ (PPD)</b>	-1083.599	0.0065506	0.0807629	0.84	5.042	-3.146
<b>MQ (PR)</b>	-1083.570	0.0069474	0.0806655	0.44	3.341	0.000
<b>DC (PR)</b>	-1083.611	0.0066874	0.0810187	0.39	2.019	0.000

MQ – Método dos mínimos quadrados  
PPD – Padrões pré-definidos

DC – Detector de cantos  
PR – Padrões reamostrados

Como pode ser observado pela Tabela 7, o método que obteve melhores resultados foi o detector de cantos usando imagens reamostradas. Os resultados da localização precisa com alvos reamostrados foram melhores do que os com alvos pré-definidos, o que já era esperado, porque não ocorre o problema de detecção com alvos de tamanhos diferentes, acarretando em incertezas nas coordenadas dos vértices aproximados da etapa de detecção de alvos. Como o erro médio quadrático obtido com o método dos mínimos quadrados com alvos pré-definidos foi elevado em relação aos outros métodos, decidiu-se comparar somente os outros dois métodos: detecção de cantos e MMQ usando alvos reamostrados (Tabela 8).

TABELA 8 – Resultados da reconstrução usando o método de detector de cantos para todos os cinco padrões.

Método usado	Coeficientes da regressão polinomial			EMQ (mm)	Erro máximo (mm)	Erro mínimo (mm)	Erro relativo
	A00	A01	A10				
<b>MQ (PR)</b>	-1083.711	0.0069474	0.0806655	0.71	6.349	0.000	1/1600
<b>DC (PR)</b>	-1083,585	0,0066416	0,0799038	0.52	5.776	0.000	1/2000

A partir destes resultados, pode-se dizer que ambos os métodos ofereceram bons resultados. A partir do EMQ pode-se afirmar que a detecção de cantos proporcionou melhores resultados para este trabalho, porém, a diferença entre os dois métodos é pequena, o que permite afirmar que ambos os métodos são bons para a localização precisa. Além disso, estes experimentos mostraram que o método de reamostragem dos padrões é significativamente melhor que o método usando padrões pré-definidos.

## CAPÍTULO VII

### 7. CONCLUSÕES E RECOMENDAÇÕES

O processo de classificação de alvos por correspondência de padrões, apresentado neste trabalho, produziu bons resultados em imagens coletadas com um sistema de luz estruturada. Como pôde ser observado, a identificação de alvos usando o método baseado em área proporcionou melhores resultados do que o método baseado em assinatura. Isto pode ser consequência dos pré-processamentos realizados como perseguição de fronteiras ou da dimensão dos alvos. Com relação ao tipo de padrões pré-definidos a serem usados (*template*), notou-se que o uso de imagens suavizadas proporcionou melhores resultados do que padrões binários. Para classificação, os padrões reamostrados em tempo real foi o que apresentou os melhores resultados.

Com relação à localização precisa usando o método de correspondência por mínimos quadrados, o método de reamostragem em tempo real dos padrões primitivos provou ser melhor que o método usando alvos pré-definidos e suas instâncias estáticas. Verificou-se, ainda, que a diferença entre os resultados proporcionados pelos métodos de detecção de cantos e de correspondência por mínimos quadrados é pequena, permitindo afirmar que ambos os métodos são equivalentes para a localização precisa. Em ambos os casos os cantos dos alvos foram localizados com precisão subpixel.

Além disso, podem-se mencionar os seguintes problemas da correspondência por mínimos quadrados: determinação dos valores aproximados



dos cantos dos padrões e a forma dos padrões projetados. O problema na forma dos padrões está relacionado a retas em que os gradientes são idênticos nestas áreas.

Uma analogia muito interessante a se mencionar neste trabalho está relacionada às duas metodologias comparadas para localização precisa. Ambos os métodos (Moravec e correspondência por padrão) determinam coordenadas aproximadas com precisão *pixel* e estas mesmas coordenadas são refinadas pelos métodos de Förstner e correspondência por mínimos quadrados.

Outras estratégias que podem ser usadas para melhorar os resultados são:

- Utilizar o conhecimento à priori a respeito das posições e das orientações da câmara e do projetor em relação ao espaço objeto para fazer a predição de localização e aspecto do alvo;
- Realizar uma predição da rotação e da escala do alvo a partir do conhecimento das distâncias e dos ângulos entre os alvos segmentados e a partir disto reamostrar os alvos primitivos. Esta estratégia parece ser confiável, porém, possui problemas em áreas de descontinuidades;
- Realizar a detecção de padrões unindo os dados obtidos pelos detectores baseados em área e baseados em contornos (assinatura);
- Realizar uma operação de melhoramento local da imagem por meio da técnica de especificação do histograma, o que deve melhorar a localização precisa dos alvos;
- Melhorar o sistema de projeção e captura com a aquisição de uma nova câmara de melhor resolução e construção.

---

## REFERÊNCIAS BIBLIOGRÁFICAS

ACKERMAN, F. **High precision digital image correlation**. Proceedings of the 39<sup>th</sup> Photogrammetric Week, Stuttgart, 1984, p. 231-243.

ANDRADE, J. B. **Fotogrametria**. Curitiba. SBEE, 1998.

ARTERO, A.O. **Técnicas para a extração automática de feições retas em imagens digitais**. Dissertação de Mestrado, Curso de Pós Graduação em Ciências Cartográficas, Presidente Prudente, 1999, 117p.

BALLARD, D.H.; BROWN, C.M. **Computer Vision**, New Jersey: Prentice-Hall, 1982, 522p.

BATTLE, J.; MOUADIBB, E.; SALVI, J. **Recent progress in coded structured light as a technique to solve the correspondence problem: a survey**. Pattern Recognition, vol. 31, nº 7, p. 963-982, 1996.

BOYER, K. L; KAK, A. C. **Color-encoded structured light for rapid range sensing**. IEEE Transactions Pattern Analysis machine Intelligence, vol. PAMI-9, nº 1, p. 14-28, 1987.

CARRIHILL, B; HUMMEL, R. **Experiments with the intensity ratio depth sensor**. Computer Vision Graphics Image Processing, vol. 32, p. 337-358, 1985.

COSTA, E. R.; TOMMASELLI, A.M.G.; GALO, M.. **Incorporação da pré-análise no processo de correspondência de pontos em Fotogrametria Digital**. XXI Congresso Brasileiro de Cartografia, Belo Horizonte, 2003.

DALLAS, R.W.A. **Architectural and archaeological Photogrammetry**. In: ATKINSON, K.B. Close range photogrammetry and machine vision. Department of Photogrammetry and Surveying, University College London. Whittles Publishing, 1996.

DREWNIOK, C.; ROHR, K. **Exterior orientation – an automatic approach based on fitting analytic landmark models**. ISPRS JOURNAL OF PHOTOGRAMMETRY & REMOTE SENSING 52, 132-145, Alemanha, 1997.

DUNN, S. M.; KEIZER, R. L. **Measuring the area and volume of the human body with structured light**. IEEE TRANSACTIONS ON SYSTEMS, MAN, AND CYBERNETICS, vol. 19, nº 6, 1989.

EL-HAKIM, S. F. **Vision-based automated measurement techniques**. In: ATKINSON, K.B. Close range photogrammetry and machine vision. Department of Photogrammetry and Surveying, University College London. Whittles Publishing, 1996.

FRASER, C.S. **Industrial measurement applications**. In: ATKINSON, K.B. Close range photogrammetry and machine vision. Department of Photogrammetry and Surveying, University College London. Whittles Publishing, 1996.

GALO, M. **Calibração e Aplicação de Câmaras Digitais**. Curitiba, 1993. Dissertação de Mestrado, Curso de Pós-Graduação em Ciências Geodésicas, UFPR.

GALO, M; TOZZI, C. L. **Extração de pontos com acurácia subpixel em imagens digitais**. Série em Ciências Geodésicas. Universidade Federal do Paraná, Curso de Pós-Graduação em Ciências Geodésicas, Curitiba, volume 2, 2002.

GEMAEL, C. **Introdução ao ajustamento de observações: aplicações geodésicas**. Curitiba, UFPR, 1994, 319p.

GONZALES, R.C., **Digital Image Processing**, Addison Wesley, New York, 1993.

GONZALEZ, R. C.; WOODS, R. E. **Processamento de Imagens Digitais**, Tradução: Roberto Marcondes César Junior e Luciano da Fontoura Costa, Ed, Edgard Blücher, São Paulo, 2000, 509p.

GRUEN, A. **Least squares matching: a fundamental measurement algorithm**. In: ATKINSON, K. B. Close range photogrammetry and machine vision. Department of Photogrammetry and Surveying, University College London. Whittles Publishing, 1996.

HARALICK, R.; SHAPIRO, L. G. **Computer and robot vision**. Reading: Addison-Wesley Publishing Company, 1993, Vol. II, 630 p.

HASEGAWA, J. K.; KÜNZLI, R.; THOMAZ, R. C. C. Corrida contra o tempo: Salvamento arqueológico. **Geoconvergência**, vol. 2, nº 2, 1999.

HATTORI, S.; AKIMOTO, K.; OKAMOTO, A.; HASEGAWA, H.; FRASER, C.S. **Design and Use of Coded Targets for Automatic Measurement with a CCD**

**Camera.** ASPRS Annual Conference. Portland, Oregon, American Society of Photogrammetry & Remote Sensing: 11, 2000.

HOWARD, A; PADGETT, C. **A generalized approach to real-time pattern recognition in sensed data.** Pattern Recognition 32, 1999, p. 2069-2071.

JAIN, A. K.; DUIN, R.P.W.; MAO, J. **Statistical Pattern Recognition: A Review.** In: IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol: 22, No. 1, 5-37:264-323, January 2000.

KEEFE, M; RILEY, D. R. **Capturing facial surface information.** Photogrammetric Engineering and Remote Sensing, vol. 52, p. 1539-1548, 1986.

KRAUS, K. **Photogrammetry – Fundamentals and Standard Processes.** DÜMMLER / BONN, volume 1, 1993.

MAAS, H.G. **Robust Automatic Surface Reconstruction with Structured Light.** In: INTERNATIONAL ARCHIVES OF PHOTOGRAMMETRY AND REMOTE SENSING. Proceedings. P.709-713. Washington, 1992.

MAYR, W.; POTH, Z. **Automatic generation of stereomodels.** JOINT ISPRS WORKSHOP WG III/2 AND IC WG II/III. Stockholm, Sweden, 1995.

MIKHAIL, E. M., BETHEL, J. S, MCGLONE, J. C. **Introduction to Modern Photogrammetry.** Ed. John Wiley & Sons, Inc. New York, 2001.

MUSTAFA, A. A. Y.; SHAPIRO, L.G.; GANTER, M.A. **3D object identification with color and curvature signatures.** Pattern recognition, 1999, 339-355.

NEWTON, I.; MITCHELL, H.L. **Medical Photogrammetry.** In: ATKINSON, K. B. Close range photogrammetry and machine vision. Department of Photogrammetry and Surveying, University College London. Whittles Publishing, 1996.

OOSTERLINCK, A.; VUYLSTEKE, P. **Range image acquisition with a single binary-encoded light pattern.** IEEE Transactions on pattern analysis and machine intelligence, vol. 12, n° 2, 1990.

OTSU, N. **A threshold selection method from gray-level histogram.** IEEE Transactions on System Man Cybernetics, Vol. SMC-9, n° 1, 1979, pp. 62-66.

REISS, M.L.L.; TOMMASELLI, A.M.G. **Calibração de um projetor de padrões para reconstrução 3D por luz estruturada**. I SIMGEO – Simpósio de Ciências Geodésicas e tecnologias da Geoinformação, Recife, 2004.

SCALCO, P.A.P. **Determinação automática de correspondência em um sistema de reconstrução com luz estruturada**. Dissertação de Mestrado. Curso de Pós Graduação em Ciências Cartográficas, FCT/UNESP, Presidente Prudente, 2000.

SCHALKOFF, R.J. **Digital image processing and computer vision**. Department of Electrical and Computer Engineering Clemson University, 1989.

SCHENK, T. **Digital Photogrammetry**. The Ohio State University, volume 1, 1999.

SONKA, M.; VAKLAV, H; BOYLE, R. **Image processing, analysis, and machine vision**. PWS PUBLISHING. 770p, 1998.

SPRING: **Tutorial de Geoprocessamento. Descrição geral do SPRING**. Disponível em: <<http://www.dpi.inpe.br/spring/teoria/index.html>>. Acesso em: 03 de março de 2003.

TING, A.; LEUNG, M. K. H.. **Form recognition using linear structure**. Pattern Recognition 32, 1999, p. 645-656.

TOMMASELLI, A.M.G. **Implementação de Um Sistema Fotogramétrico Digital Para Reconstrução de Imagens**. Relatório Final de Bolsa de Pesquisa, nível 2c, apresentado ao CNPq, Faculdade de Ciências e Tecnologia, Unesp, Presidente Prudente, 1997, 115p.

TOMMASELLI, A. M. G.; GALO, M.; HASEGAWA, J. K. **Modernas Tecnologias de Aquisição de Imagens em Fotogrametria**. BOLETIM DE CIÊNCIAS GEODÉSICAS. Curitiba, v. 6, nº 1, p. 49-64, 2000.

TOMMASELLI, A. M. G.; GALO, M.; HASEGAWA, J. K. **Desenvolvimento de uma biblioteca de funções e classes para Fotogrametria**. XXI Congresso Brasileiro de Cartografia, Belo Horizonte, 2003.

WANG, Y. F.; MITICHE, A.; AGGARWAL, J. K. **Computation of surface orientation and structure of objects using grid coding**. IEEE Transactions on Pattern Analysis Machine Intelligence, vol. PAMI-9, nº 1, p. 129-137, 1987.

WOLF, P.R. **Elements of Photogrammetry, with air photo interpretation and remote sensing**. McGRAW-HILL International Editions, 1983.

This document was created with Win2PDF available at <http://www.daneprairie.com>.  
The unregistered version of Win2PDF is for evaluation or non-commercial use only.